

Universidad Internacional de La Rioja
Facultad de Economía y Empresa

Máster Universitario en Business Intelligence y Analítica

Proyecto en colaboración con Altadis, S.A. — Imperial Brands Group | Red Proyectium

Optimización del route to market en
el sector tabacalero: un enfoque de
Business Intelligence y analítica
predictiva aplicado a Altadis España

Trabajo fin de estudio presentado por:	Carlos Baztán Peiró
Tipo de trabajo:	Proyecto de Inteligencia de Negocio
Modalidad:	Individual
Director/a:	Enrique Hortalá González
Fecha:	12/07/2026

ÍNDICE

Introducción

2. Objetivos

3. Fuentes de datos

- 3.1. Datos internos
- 3.2. Fuentes externas

4. Metodología a seguir

- 4.1. Herramientas
- 4.2. Preparación y limpieza de los datos
- 4.3. Modelo de datos
- 4.4. Análisis y modelos
- 4.5. Aplicación a la toma de decisiones
- 4.6. Propuesta de enfoque analítico del TFM
- 4.7. Desglose Anatómico de las Fuentes de Datos Originales
- 4.8. Alcance

5. Estructura de los Datos Originales

- 5.1. Tabla: Affiliated_Outlets
- 5.2. Tabla: Product
- 5.3. Tabla: SalesDay
- 5.4. Tabla: DeliveryDay
- 5.5. Tabla: OoSDay
- 5.6. Tabla: RouteDay

6. Modelo Relacional y Claves de Unión

- 6.1. Variables Clave de Unión
- 6.2. Tipo de Relaciones
- 6.3. Posibilidades Analíticas

7. Análisis Exploratorio de Datos y Hallazgos Descriptivos

- 7.1. Auditoría de calidad e integridad del dato
- 7.2. Caracterización de la red de puntos de venta
- 7.3. Análisis de ventas por producto y formato
- 7.4. Análisis de roturas de stock
- 7.5. Cadena de suministro: entregas y cobertura de rutas
- 7.6. Patrones temporales y estacionalidad semanal
- 7.7. Síntesis y conexión con la fase de modelización

8. Análisis de la calidad y consistencia de los datos

- 8.1. Metodología de auditoría
- 8.2. Incidencias detectadas y tratamiento aplicado
- 8.3. Conclusión de la auditoría de calidad

9. Diseño e implementación del Data Warehouse

- 9.1. Arquitectura del modelo dimensional
- 9.2. Construcción de la tabla integrada (staging)
- 9.3. Validación de la tabla integrada
- 9.4. Integración de variables externas agregadas
- 9.5. Materialización del modelo dimensional: extracción de FACT y DIM
- 9.6. Cierre del objetivo 2

10. Clusterización de outlets y modelos predictivos

- 10.1. Planteamiento y alcance
- 10.2. Selección y preparación de variables
- 10.3. Codificación de la variable Tam_m2
- 10.4. Estandarización y elección del número de clusters
- 10.5. Detección y tratamiento de un cluster degenerado
- 10.6. Resultado final: cinco segmentos de outlet
- 10.7. Interpretación de negocio de cada segmento
- 10.8. Predicción de rotura de stock (clasificación binaria)
- 10.9. Análisis exploratorio previo
- 10.10. Resultados y comparación de modelos
- 10.11. Interpretación y conclusiones
- 10.12. Limitaciones del objetivo 4

11. Introducción y objeto del informe

- 11.1. Advertencia metodológica sobre la cobertura temporal
- 11.2. Metodología de construcción

12. Resumen Ejecutivo

- 12.1. Indicadores clave (tarjetas)
- 12.2. Mix de ventas por formato
- 12.3. Ventas netas por provincia

13. Geografía y Renta

- 13.1. Ventas por estanco frente a renta provincial
- 13.2. Ranking de provincias por volumen
- 13.3. Ventas por tipo de ubicación
- 13.4. Ventas por tamaño del local

14. Stock y Logística

- 14.1. Indicadores globales
- 14.2. Rotura de stock por formato
- 14.3. Tasa de rotura de stock por provincia
- 14.4. Rotura por ubicación
- 14.5. Efecto de la ruta de reparto

15. Estacionalidad

- 15.1. Indicadores globales
- 15.2. Venta media por día
- 15.3. Volumen por día de la semana
- 15.4. Reposición media por día
- 15.5. Efecto festivo frente a laborable

16. Síntesis de hallazgos

17. Conclusiones

- 17.1. Principales hallazgos de negocio
- 17.2. Limitaciones del estudio
- 17.3. Recomendaciones para Altadis / Imperial Brands
- 17.4. Líneas futuras de trabajo
- 17.5. Reflexión final

Bibliografía

Anexo A. Validación final del modelo dimensional (Data Warehouse)

- A.1. Resumen de tablas físicas
- A.2. Verificación de integridad referencial
- A.3. Comandos representativos del proceso de construcción

Anexo B. Cuadro de mando Power BI: estructura y visualizaciones

Anexo C. Notebook de predicción de rotura de stock (Objetivo 4)

- C.1. Planteamiento y variables
- C.2. Modelos comparados
- C.3. Criterio de evaluación

Anexo D. Notebook de clustering de outlets (Objetivo 4)

- D.1. Variables y estandarización
- D.2. Elección del número de clusters
- D.3. Detección y exclusión de un cluster degenerado
- D.4. Perfiles finales de los cinco clusters

1. INTRODUCCIÓN

El sector tabacalero español atraviesa un contexto de transformación marcado por una creciente presión regulatoria, continuas subidas fiscales, restricciones en materia publicitaria y una evolución constante en los hábitos de consumo. A ello se suma la consolidación de nuevas categorías de producto, como los dispositivos de nueva generación, que están redefiniendo la dinámica competitiva del mercado. En este escenario, la capacidad de las empresas para comprender su actividad comercial, optimizar su red de distribución y anticiparse a los cambios del mercado se ha convertido en un factor estratégico clave.

Este trabajo se desarrolla en colaboración con Altadis, S.A., filial española de Imperial Brands Group, uno de los principales operadores del sector tabaquero a nivel nacional e internacional. La compañía opera tanto en el segmento tradicional de productos de tabaco y complementos como en nuevas categorías de consumo, apoyándose en una extensa red de distribución en la que los estancos desempeñan un papel central como canal estratégico de comercialización. La ubicación, comportamiento y operativa de estos puntos de venta constituye un elemento fundamental dentro de la estrategia comercial de la compañía, especialmente desde una perspectiva de análisis del denominado *route to market*, entendido como el conjunto de procesos, agentes y canales que intervienen desde la producción hasta la venta final al consumidor.

Con el objetivo de avanzar hacia una visión más integral de este proceso, Altadis ha puesto a disposición de este proyecto distintos conjuntos de datos operacionales anonimizados que recogen información relativa a establecimientos afiliados, catálogo de productos, ventas diarias, reposición de mercancía, incidencias de rotura de stock y planificación logística de reparto. De manera aislada, cada una de estas fuentes aporta únicamente una visión parcial de la actividad; sin embargo, integradas bajo una misma estructura analítica, permiten construir una imagen mucho más completa del funcionamiento real del negocio.

En este contexto, el presente trabajo plantea el diseño de una estructura de datos centralizada que actúe como repositorio único de información, integrando tanto los datos internos proporcionados por la compañía como fuentes externas de valor añadido, especialmente de carácter geográfico, socioeconómico y temporal. Sobre esta base, se desarrollará un enfoque de Business Intelligence orientado a la construcción de indicadores clave, cuadros de mando y análisis visuales que faciliten la interpretación de la información, complementado con técnicas de analítica avanzada y modelización predictiva aplicadas a la previsión de ventas, la demanda y la detección de posibles roturas de stock.

Más allá del componente técnico, el propósito de este trabajo es transformar datos operativos en conocimiento accionable, aportando una base sólida para mejorar la toma de decisiones comerciales, logísticas y estratégicas dentro de Imperial Brands. En definitiva, se trata de convertir información dispersa en una herramienta real de inteligencia de negocio, capaz de generar valor tangible para la organización.

2. OBJETIVOS

El objetivo general del presente proyecto es desarrollar una solución de Business Intelligence aplicada al negocio de Altadis en España, orientada a transformar los datos operacionales disponibles en información estructurada, conocimiento útil e insights accionables que faciliten la toma de decisiones comerciales, logísticas y estratégicas dentro de Imperial Brands.

Para alcanzar este propósito, el trabajo se articula en torno a cuatro líneas principales de actuación

1. **Analizar la calidad, consistencia y fiabilidad de los datos disponibles**, identificando posibles limitaciones, descuadres, valores atípicos e inconsistencias, con el fin de establecer un proceso de limpieza, transformación y preparación que garantice una base sólida sobre la que desarrollar el resto del análisis.

2. **Diseñar e implementar una estructura de datos centralizada (Data Warehouse),** en forma de repositorio único o *Data Warehouse*, que integre la información interna que se nos ha proporcionado desde un primer momento, con fuentes externas de valor añadido, especialmente de carácter geográfico, socioeconómico y temporal, permitiendo una visión integrada y enriquecida del negocio.
3. **Desarrollar un sistema de visualización e indicadores de negocio,** mediante cuadros de mando interactivos y KPIs relevantes, que permitan monitorizar el rendimiento comercial y operativo de la compañía, detectar patrones de comportamiento, contextualizar la información y facilitar una toma de decisiones basada en datos por parte de los distintos responsables de negocio.
4. **Aplicar técnicas de analítica avanzada y modelización predictiva** sobre la base de datos construida, con el objetivo de identificar relaciones entre variables, anticipar tendencias de demanda, estudiar patrones de venta y roturas de stock, y generar modelos que aporten valor práctico en ámbitos como la planificación comercial, la optimización logística y la mejora de la disponibilidad de producto en el punto de venta.
5. **Generación de insights empresariales:** Producir información accionable basada en el análisis de los datos proporcionados.

3. FUENTES DE DATOS

3.1. Datos internos

La base del proyecto son seis ficheros CSV proporcionados directamente por Altadis, que recogen información operacional de su red de distribución durante el año 2015. Todos han sido anonimizados previamente por la empresa.

Fichero	Descripción
Affiliated_Outlets.csv	Información de los establecimientos afiliados (estancos): identificador, ubicación, tamaño y clasificación comercial.
Product.csv	Catálogo de productos comercializados con sus características básicas.
DeliveryDay.csv	Registro diario de entregas de mercadería realizadas en cada establecimiento.
OoSDay.csv	Incidencias de rotura de stock declaradas por cada punto de venta.
RouteDay.csv	Calendario de rutas de reparto programadas para cada establecimiento.
SalesDay.csv	Ventas diarias registradas por establecimiento y producto.

Estos ficheros no están exentos de problemas. Algunos presentan inconsistencias entre sí, otros tienen registros atípicos que responden a correcciones operativas, y la calidad de ciertos datos declarativos depende en gran medida de la disciplina de registro de cada punto de venta. Gestionar todo eso es, de hecho, una parte importante del trabajo.

3.2. Fuentes externas

Para situar los datos internos en un contexto más amplio y enriquecer el análisis, se han incorporado fuentes de información estadística oficial sobre el entorno socioeconómico y el calendario laboral.

Además, se aprovecharán fuentes estadísticas oficiales para enriquecer la dimensión del consumidor y el entorno geográfico. Entre ellas, encuestas y estudios del Instituto Nacional de Estadística (INE) sobre hábitos de consumo, estructura de la población por zonas y niveles de renta, que permiten relacionar el comportamiento de cada punto de venta con el perfil socioeconómico de su entorno.

4. METODOLOGÍA A SEGUIR

El proyecto adopta la metodología CRISP-DM como marco de referencia. Es el estándar habitual en proyectos de Business Intelligence y minería de datos, y tiene la ventaja de ser iterativo: no obliga a avanzar en línea recta, sino que permite volver a fases anteriores cuando los datos o los resultados así lo exigen. En un proyecto como este, donde se parte de datos reales con imperfecciones conocidas, esa flexibilidad es importante.

4.1. Herramientas

Se utilizarán las herramientas trabajadas a lo largo del máster, todas en un nivel básico-intermedio. La combinación cubre las distintas fases del proyecto de forma coherente:

Herramienta	Uso en el proyecto
Power Query	Transformación, limpieza y preparación inicial de los datos.
SQL	Datawarehouse - Gestión del modelo de datos y consultas analíticas.
Python	Análisis exploratorio, modelos predictivos y segmentación.
R / RStudio	Análisis estadístico complementario y visualización.
Power BI	Dashboard de indicadores para la dirección de Imperial Brands.

4.2. Preparación y limpieza de los datos

Antes de cualquier análisis, los datos necesitan pasar por un proceso de limpieza y homogeneización. Esta fase consiste en revisar cada fichero, detectar los problemas que presenta (valores incorrectos, registros duplicados, inconsistencias,...) y tomar decisiones documentadas sobre cómo tratarlos. El objetivo no es tener datos perfectos, que no existen, sino tener datos confiables y saber exactamente qué limitaciones tienen.

Junto con la limpieza, se realizó el enriquecimiento de los datos internos con fuentes externas de carácter geográfico (códigos postales y provincias del INE), socioeconómico (renta media provincial del INE, año 2015) y temporal (calendario de festivos laborales del BOE para 2015), incorporando información de contexto que por sí sola la empresa no disponía.

4.3. Modelo de datos

Una vez preparados los datos, se diseñó una estructura centralizada que los integra de forma coherente y sirve como base única para todos los análisis. Se seguirá un enfoque de modelado dimensional, habitual en proyectos de Business Intelligence, que organiza la información en torno a las variables de negocio más relevantes: el establecimiento, el producto, el tiempo y la ubicación geográfica.

Este modelo es la fuente de verdad del proyecto: cualquier indicador, gráfico o modelo predictivo desarrollado, parte de él.

4.4. Análisis y modelos

Con el modelo de datos construido, el trabajo analítico se ha desarrollado en dos niveles. El primero es descriptivo: entender qué ha pasado en la red de distribución durante el período analizado, identificar patrones de comportamiento y cuantificar los indicadores clave del negocio. Este nivel alimentará directamente el dashboard de Power BI.

El segundo nivel es predictivo y de segmentación. A partir del historial de datos se desarrollaron modelos de clasificación para anticipar el riesgo de rotura de stock y técnicas de clustering para identificar perfiles diferenciados de outlet dentro de la red de distribución. La predicción de ventas y demanda se plantea como línea de trabajo futura. La complejidad técnica de los modelos implementados se ha ajustado al nivel de dominio de las herramientas trabajadas durante el máster.

4.5. Aplicación a la toma de decisiones

El resultado final del proyecto tiene que ser útil para alguien que no sabe nada de datos. Los análisis y modelos desarrollados se trasladarán a un dashboard en Power BI pensado para perfiles directivos: una herramienta visual, clara y filtrable, que permita responder preguntas de negocio concretas sin necesidad de entrar en el detalle técnico.

Más allá del dashboard, los resultados del proyecto se han traducido en decisiones de negocio accionables: cómo priorizar la atención comercial según el perfil de cada outlet, cómo mejorar la regularidad logística de la red de distribución, o qué segmentos de la red merecen una atención diferenciada en función de su rendimiento histórico de venta. Ese es, en última instancia, el criterio con el que se evaluará si el trabajo ha servido para algo.

4.6. Propuesta de enfoque analítico del TFM

4.6.1. Tenemos

Internamente:

- **Ventas (SalesDay)** → variable objetivo principal (qué se vende, cuándo, dónde y qué producto).
- **Entregas / reposición (DeliveryDay)** → volumen entregado a cada punto de venta.
- **Roturas de stock (OosDay)** → momentos en los que el producto no está disponible.
- **Calendario de reparto (RouteDay)** → frecuencia y patrón logístico.
- **Tiendas / Código Postal (AffiliatedOutlets)** → ubicación geográfica.

- **Productos (Product)** → segmentación por marca, categoría y tipología.

Solo con estas fuentes ya puede construirse un análisis sólido y con valor real.

4.6.2. Análisis geográfico y socioeconómico

Variables a añadir: Provincia (derivada del código postal mediante cruce con la tabla de códigos postales del INE) y renta media provincial por habitante (INE, 2015).

Qué hacer: enriquecer cada punto de venta con su provincia y cruzarlo con ventas, roturas y producto. Analizar volumen de ventas por provincia, ratio ventas por tienda, incidencia de roturas por zona y posible relación entre renta y comportamiento de consumo.

Valor para Imperial: segmentación territorial, focalización comercial y optimización regional.

Aplicación: mapas y dashboards en Power BI + variables predictoras para modelos.

4.6.3. Relación ventas – entregas

Variables clave: volumen vendido, volumen entregado, frecuencia de entrega y días desde última reposición.

Qué hacer: cruzar ventas y entregas por fecha, tienda y producto. Calcular ratios entrega/venta, detectar exceso o falta de suministro y analizar cómo influye la frecuencia logística en la venta.

Preguntas clave: ¿más frecuencia implica más ventas?, ¿qué zonas están desabastecidas?, ¿dónde hay sobrestock?

Valor para Imperial: mejora de eficiencia logística, optimización de rutas y ajuste del suministro a la demanda real.

4.6.4. Roturas de stock (bloque estrella)

Variables clave: frecuencia de OOS, producto afectado, zona afectada y momento temporal.

Qué hacer: cruzar **OosDay** con ventas, entregas, producto y provincia. Identificar qué productos fallan más, dónde ocurre y bajo qué contexto (alta demanda, baja reposición, festivos, etc.).

Qué estudiar: cuándo ocurren, dónde, en qué productos y si están relacionadas con mala previsión o mala reposición.

Valor para Imperial: reducir ventas perdidas, mejorar disponibilidad y minimizar fuga a la competencia.

4.6.5. Calendario y estacionalidad

Variables a añadir: festivo, pre-festivo, mes, trimestre, día de la semana y estación del año.

Qué hacer: construir una tabla calendario y cruzarla con ventas y OOS. Analizar patrones semanales, mensuales y estacionales, así como impacto de festivos y puentes.

Valor para Imperial: anticipación de demanda, mejor planificación logística y mayor precisión en previsiones.

4.6.6. Modelo predictivo (parte final)

Objetivo: predecir ventas futuras.

Variables del modelo: provincia, categoría de producto, histórico de ventas, volumen entregado, incidencia de OOS, festivos y variables temporales.

Qué hacer: construir el dataset de entrenamiento integrando variables de contexto (calendario, características del outlet, patrón de entrega), entrenar y comparar tres modelos de clasificación en Python (Regresión Logística, Árbol de Decisión y XGBoost) con técnicas de balanceo de clases, y evaluar los resultados mediante Accuracy, Precision, Recall y F1-score.

Valor para Imperial: estimar demanda futura, mejorar planificación comercial y optimizar stock y reposición.

4.6.7. Enfoque recomendado

Datos internos (80%) → ventas, entregas, stock out, rutas, producto y tiendas.

Datos externos (20%) → provincia, renta media y festivos.

4.7. Desglose Anatómico de las Fuentes de Datos Originales

La base de este proyecto reside en la integración de múltiples dimensiones y hechos transaccionales contenidos en el archivo `Altadis_Dataset_Unificado.xlsx`. Este archivo se compone de diversas hojas que representan los pilares informativos del negocio:

Por un lado, las dimensiones maestras, que incluyen la hoja `Affiliated_Outlets`, donde se detallan los puntos de venta con variables críticas como el código postal, el clúster de gestión, el tamaño del local (`Tam_m2`) y la clasificación de ubicación (`Location`), permitiendo entender el contexto físico de cada venta. A esto se suma la hoja `Product`, que normaliza el catálogo mediante el código de producto, su tamaño y formato (como `ASL` o `ATA`), asegurando la integridad de los artículos en toda la cadena.

Por otro lado, encontramos las tablas de hechos o transaccionales: `SalesDay` y `DeliveryDay`, que registran respectivamente las unidades vendidas y entregadas por día, producto y cliente; `OoSDay`, que captura los eventos de fuera de stock (`Out of Stock`) para identificar brechas en la disponibilidad; y `RouteDay`, que vincula la planificación logística de rutas con los puntos de venta específicos visitados cada jornada.

4.7.1. Impacto en la Inteligencia de Negocio y Análisis de Resultados

La culminación de este proceso de ingeniería de datos sobre la tabla de datos unificada, dota al sistema de una capacidad analítica de alto nivel, permitiendo pasar de una gestión reactiva a una toma de decisiones basada en datos empíricos.

Al tener integradas las ventas, las entregas y las roturas de stock en un mismo repositorio, es posible realizar un análisis de "Venta Perdida", cuantificando el impacto económico de

los registros en la tabla OoSDay sobre el rendimiento total. Asimismo, la vinculación de la tabla RouteDay permite medir la eficiencia operativa, evaluando si las rutas de distribución planificadas están alineadas con los puntos de venta de mayor volumen o si existen ineficiencias en el suministro según el clúster de gestión. Este Data Warehouse no solo actúa como un histórico de transacciones, sino que se convierte en la infraestructura necesaria para implementar cuadros de mando avanzados (Dashboards) que visualicen el ciclo de vida del producto en el punto de venta, optimizando la logística de Altadis y mejorando la tasa de servicio final al cliente.

4.7.2. Implementación de Inteligencia de Negocio y Optimización Estratégica

El último bloque del texto debe centrarse en cómo este sistema integrado a partir del **Altadis_Dataset_Unificado.xlsx** resuelve problemas de negocio reales. En esta sección se deben detallar los casos de uso analítico que justifican el proyecto.

- **Análisis de la Venta Perdida (Lost Sales Analysis):** Cruzando OoSDay con los promedios de SalesDay, el sistema calcula el impacto económico de cada rotura de stock. Este KPI se vuelve estratégico para el departamento de operaciones, permitiendo priorizar el suministro hacia los puntos de venta con mayor rentabilidad histórica o mayor tamaño (Tam_m2).
- **Evaluación de la Eficiencia de Ruta:** Al analizar la hoja RouteDay, el Data Warehouse permite detectar ineficiencias logísticas. Por ejemplo, se puede visualizar si los puntos de venta con ubicación "Countryside" reciben más visitas de las necesarias en comparación con su volumen de ventas real, permitiendo una reestructuración de las rutas para ahorrar costes de transporte y combustible.

- **Segmentación Geográfica y Estacional:** Gracias a la variable **Location**, el analista puede descubrir que los productos con un determinado **Format** (por ejemplo, ATA) tienen picos de demanda en zonas de "Leisure" durante periodos vacacionales. Esta información permite a Altadis realizar cargas de stock preventivas, asegurando que el producto esté disponible antes de que la demanda aumente, eliminando así los eventos de OoS.

4.8. Alcance

El alcance del proyecto abarca el procesamiento de un total de 6 ficheros CSV originales con un volumen combinado de más de 2,1 millones de registros, incluyendo:

Fichero	Registros	Descripción
SalesDay.csv	1.048.575	Registro diario de ventas por outlet y producto
DeliveryDay.csv	615.141	Registro diario de entregas por outlet y producto
OoSDay.csv	262.278	Eventos de rotura de stock (Out of Stock)
RouteDay.csv	94.858	Rutas comerciales diarias por outlet
Affiliated_Outlets.csv	3.583	Maestro de puntos de venta afiliados
Product.csv	60	Maestro de productos con formato y tamaño

5. ESTRUCTURA DE LOS DATOS ORIGINALES

Antes de proceder con la integración, se realizó un análisis exhaustivo de cada una de las tablas originales para comprender su estructura, tipología de variables y posibles claves de relación. A continuación se detalla el esquema de cada tabla.

5.1. Tabla: Affiliated_Outlets

Tabla de puntos de venta. Actúa como tabla central del modelo relacional, siendo la principal fuente de información descriptiva sobre cada outlet afiliado. Contiene 3.583 registros únicos.

Campo	Tipo	Descripción
Affiliated_Code	VARCHAR (PK)	Código único identificador del outlet — clave principal de unión
Affiliated_NAME	VARCHAR	Nombre comercial del punto de venta
POSTALCODE	INTEGER	Código postal de la ubicación del outlet
Engage	INTEGER	Nivel de engagement o vinculación comercial (0–5)
Management_Cluster	INTEGER	Agrupación de gestión interna (clúster de management)
Location	VARCHAR	Tipo de ubicación (BORDER, ANY, VACATIONAL, etc.)
Tam_m2	VARCHAR	Tamaño del local en metros cuadrados (ej. >20m2)

5.2. Tabla: Product

Tabla de productos. Contiene el catálogo completo de referencias de producto comercializadas por Altadis. Con solo 60 registros, es la tabla más pequeña del modelo pero esencial para enriquecer cualquier análisis de ventas o entregas.

Campo	Tipo	Descripción
Product_Code	VARCHAR (PK)	Código único del producto — clave de unión con tablas transaccionales
SIZE	INTEGER	Tamaño del producto en unidades (ej. 85, 142)
Format	VARCHAR	Formato del producto (ej. ASL, KS)

5.3. Tabla: SalesDay

Tabla transaccional de ventas diarias. Es la tabla de mayor volumen del dataset con 1.048.575 registros. Recoge las unidades vendidas de cada producto en cada outlet para cada día. Constituye el núcleo del análisis de negocio.

Campo	Tipo	Descripción
Sales_DAY	INTEGER (YYYYMMDD)	Fecha de la venta en formato numérico
Affiliated_Code	VARCHAR (FK)	Código del outlet — enlaza con Affiliated_Outlets
Product_Code	VARCHAR (FK)	Código del producto — enlaza con Product
Sales_Uds	INTEGER	Unidades vendidas en esa fecha

5.4. Tabla: DeliveryDay

Tabla transaccional de entregas diarias. Registra las unidades entregadas a cada outlet por producto y día, con 615.141 registros. Permite analizar la cadena de suministro y comparar entregas versus ventas para detectar eficiencias o roturas.

Campo	Tipo	Descripción
Delivery_DAY	INTEGER (YYYYMMDD)	Fecha de la entrega en formato numérico
Affiliated_Code	VARCHAR (FK)	Código del outlet — enlaza con Affiliated_Outlets
Product_Code	VARCHAR (FK)	Código del producto — enlaza con Product
Delivery_Uds	INTEGER	Unidades entregadas en esa fecha

5.5. Tabla: OoSDay

Tabla de roturas de stock. Registra los días en que un producto específico no estaba disponible en un outlet determinado, con 262.278 registros. Este dato es crítico para el análisis de disponibilidad y eficiencia de la distribución.

Campo	Tipo	Descripción
OoS_DAY	INTEGER (YYYYMMDD)	Fecha del evento de rotura de stock
Affiliated_Code	VARCHAR (FK)	Código del outlet — enlaza con Affiliated_Outlets
Product_Code	VARCHAR (FK)	Código del producto — enlaza con Product

5.6. Tabla: RouteDay

Tabla de rutas comerciales diarias. Registra qué outlets fueron visitados en cada jornada comercial, con 94.858 registros. Permite analizar la cobertura de la red comercial y cruzar visitas con ventas o eventos de stock.

Campo	Tipo	Descripción
Route_DAY	INTEGER (YYYYMMDD)	Fecha de la visita comercial
Affiliated_Code	VARCHAR (FK)	Código del outlet visitado — enlaza con Affiliated_Outlets

6. MODELO RELACIONAL Y CLAVES DE UNIÓN

Tras el análisis de las tablas, se identificaron dos variables que actúan como ejes vertebradores del modelo de datos y permiten correlacionar todas las tablas entre sí mediante relaciones de tipo JOIN estándar SQL.

6.1. Variables Clave de Unión

Variable	Tipo	Rol	Tablas que la contienen
Affiliated_Code	VARCHAR	Clave principal (PK en Outlets, FK en resto)	Affiliated_Outlets, SalesDay, DeliveryDay, OoSDay, RouteDay
Product_Code	VARCHAR	Clave secundaria (PK en Product, FK en resto)	Product, SalesDay, DeliveryDay, OoSDay

6.2. Tipo de Relaciones

Todas las uniones entre tablas son de tipo LEFT JOIN, garantizando que se conserven todos los registros de las tablas transaccionales (hechos) incluso si no tienen correspondencia exacta en las tablas maestras (dimensiones). Esto es especialmente relevante en datasets reales donde pueden existir códigos de outlet o producto que hayan sido dados de baja pero cuyos registros históricos se mantienen.

Join	Tablas	Cardinalidad	Observación
SalesDay → Affiliated_Outlets	Affiliated_Code	N:1	Muchas ventas por outlet
SalesDay → Product	Product_Code	N:1	Muchas ventas por producto
DeliveryDay → Affiliated_Outlets	Affiliated_Code	N:1	Muchas entregas por outlet
DeliveryDay → Product	Product_Code	N:1	Muchas entregas por producto
OoSDay → Affiliated_Outlets	Affiliated_Code	N:1	Muchos OoS por outlet
OoSDay → Product	Product_Code	N:1	Muchos OoS por producto
RouteDay → Affiliated_Outlets	Affiliated_Code	N:1	Muchas rutas por outlet

6.3. Posibilidades Analíticas

La integración realizada habilita un amplio abanico de análisis de negocio. A continuación se describen los principales casos de uso:

6.3.1. Análisis de Ventas

- Ventas totales por outlet, región, clúster de gestión o tipo de ubicación.
- Evolución temporal de ventas por producto (por formato ASL/KS y tamaño).
- Ranking de outlets por volumen de ventas y comparativa por segmento.
- Análisis de estacionalidad: ventas en outlets de tipo VACATIONAL vs. BORDER vs. ANY.
- Impacto del nivel de engagement (variable Engage) en el volumen de ventas.

6.3.2. Análisis de Distribución y Entregas

- Cobertura de entregas por zona geográfica (código postal) y clúster.
- Ratio entregas/ventas por producto para detectar sobrestock o substock.
- Análisis de frecuencia y volumen de entregas por outlet.
- Comparativa entre unidades entregadas y vendidas para optimizar la cadena de suministro.

6.3.3. Análisis de Out of Stock

- Frecuencia de eventos OoS por outlet y producto: identificar los puntos críticos.
- Correlación entre OoS y ventas: ¿cuántas ventas potenciales se pierden?
- OoS por clúster de gestión: detectar si hay zonas con mayor incidencia.
- Productos con mayor tasa de rotura: priorización del reaprovisionamiento.

6.3.4. Análisis de Rutas Comerciales

- Cobertura de visitas comerciales por outlet y día de la semana.
- Correlación entre visitas comerciales y ventas: ¿la visita genera incremento?
- Outlets no visitados en un período determinado: oportunidades de mejora.
- Eficiencia de rutas por clúster de gestión y tipo de ubicación.

6.3.5. Clasificación Estratégica de Productos: Formatos ASL, ATA y ETO

Atributo Técnico	ASL (American Style Line)	ATA (Advanced Tobacco Architecture)	ETO (Emerging/External Trade Ops)
Marcas Representativas	Fortuna, JPS, West, Nobel	Davidoff, Gauloises Premium, Pulze/iD	Rizla, Zone X, Skruf, Drum
Códigos en Dataset	Brit090, Brit700, Dome004, Dome104	Dome200, Dome797, Inte190, Don843	Dome206, Fren043, Inte404, Fren628
Rol en el Data Warehouse	Motor de Volumen: representa la mayoría de los registros en SalesDay.	Generador de Valor: productos con mayor margen por unidad en DeliveryDay.	Innovación/Accesorios: categorías de crecimiento o productos complementarios.
Sensibilidad al Stock	Crítica: una falta en OoSDay supone una pérdida masiva de cuota.	Estratégica: la falta de stock daña la imagen de exclusividad de la marca.	Oportunista: ligada a ventas cruzadas (ej. papel + tabaco de liar).
Ubicación Predominante	Generalizada (Urbano, Rural, Countryside).	Concentrada en Leisure (ocio) y Border (fronteras).	Específica por canal (estancos especializados o zonas de tránsito).
Fidelidad del Cliente	Alta sensibilidad al precio (Challenger Brands).	Alta fidelidad a la marca y al formato (Premium).	Consumidor joven o adaptado a nuevas categorías (Vape/Oral).

Lógica de Agregación: En la construcción del Data Warehouse, la tabla anterior define la jerarquía de agrupación de datos. Mientras que los registros **ASL** se analizan mediante funciones de suma masiva para entender la cuota de mercado, los registros **ATA** y **ETO** requieren un análisis de varianza más fino para identificar oportunidades en segmentos de nicho.

Impacto en la Cadena de Suministro: La distinción entre estos formatos permite que el motor SQL automatice alertas de reposición diferenciadas. Por ejemplo, una rotura de stock (**OoSDay**) en un código **ASL** dispara una alerta de prioridad logística alta, mientras que una incidencia en un código **ETO** se analiza bajo una óptica de penetración de mercado y prueba de producto.

Enriquecimiento del Modelo Relacional: Al cruzar estos formatos con la hoja **Affiliated_Outlets**, el modelo permite visualizar geográficamente la estrategia de Imperial Brands: la ubicuidad de las marcas **ASL** frente a la exclusividad territorial de las marcas **ATA**, optimizando así la planificación de rutas reflejada en la tabla **RouteDay**.

Al analizar el archivo del Datawarehouse, observamos que los nombres de las marcas están "enmascarados" tras los códigos de producto (como Dome, Brit o Fren). Sin embargo, basándonos en la estructura logística típica de la compañía y el portafolio de Imperial Brands, aquí tienes la explicación técnica detallada de lo que representan estos formatos:

6.3.6. El Formato ASL (American Style / Standard Line)

En los archivos de datos, el código ASL agrupa a las marcas de "Cigarrillo Tradicional" (Combustibles).

- **Marcas asociadas:** Aquí se encuentran los grandes pilares de volumen de Imperial Brands como JPS (John Player Special), West y las joyas locales españolas Fortuna y Nobel.

- Características: Los códigos que empiezan por Brit (como Brit090) o Dome (como Dome004) suelen estar categorizados como ASL.
- Importancia técnica: Es el segmento con mayor rotación en las tablas de SalesDay. Sus roturas de stock (OoSDay) impactan directamente en el KPI de volumen total.

6.3.7. El Formato ATA (Advanced Tobacco Architecture / Premium)

El formato ATA suele identificar a productos con características de diseño superiores o ediciones específicas de marcas Premium.

- Marcas asociadas: Principalmente Davidoff y ediciones especiales de Gauloises. También puede incluir productos de "Tobacco Heating Products" (THP) como las unidades de Pulze/iD debido a su arquitectura de producto diferenciada.
- Características: Encontramos códigos como Dome200 o Inte190 bajo esta etiqueta.
- Importancia técnica: Representan el valor del ticket promedio. En tu análisis de SQL, verás que aunque tienen menos volumen de ventas que los ASL, su rentabilidad por unidad entregada (DeliveryDay) es superior.

6.3.8. El Formato ETO (External Trade Operations/Emerging)

El código ETO suele referirse a productos destinados a canales específicos o formatos de exportación/especiales que no siguen la línea estándar de distribución masiva.

- Marcas asociadas: Puede incluir marcas de nicho, tabaco de liar (Fine Cut) como Rizla (en sus formatos de papel/accesorios) o marcas de Oral Nicotine (bolsitas de nicotina como Zone X).
- Características: Se asocia a códigos como Dome206 o Fren043.
- Importancia técnica: En el Data Warehouse, estos productos muestran patrones de venta muy estacionales o muy ligados a ubicaciones específicas (como zonas de "Leisure" o "Border" en la hoja Affiliated_Outlets).

7. ANÁLISIS EXPLORATORIO DE DATOS Y HALLAZGOS

DESCRIPTIVOS

(Fase de Data Understanding y resultados descriptivos — CRISP-DM)

Una vez descritas las fuentes, definida la metodología y diseñado el modelo relacional, este apartado materializa la fase de comprensión del dato (Data Understanding) de CRISP-DM y avanza los primeros resultados descriptivos del proyecto. Hasta este punto el trabajo ha enumerado lo que se puede analizar; aquí se cuantifica lo que efectivamente ocurre en la red de distribución de Altadis durante el período disponible, sobre la base del repositorio unificado Altadis_Dataset_Unificado.xlsx. El objetivo es doble: por un lado, auditar la calidad real de la información antes de modelizar; por otro, extraer patrones de negocio que orienten tanto el cuadro de mando de Power BI como las variables del modelo predictivo posterior.

Todas las cifras de este apartado se han obtenido directamente del dataset integrado y se acompañan, cuando procede, de la advertencia sobre las limitaciones de la fuente. Esta transparencia es deliberada: en un proyecto de Business Intelligence el valor no reside en presentar datos perfectos, sino en conocer con exactitud qué se está midiendo y con qué cobertura.

7.1. Auditoría de calidad e integridad del dato

Antes de interpretar cualquier indicador, se ha realizado una auditoría sistemática de las siete hojas del repositorio. Los volúmenes reales cargados y las incidencias detectadas se resumen a continuación, y condicionan el alcance de todo el análisis posterior.

Hoja	Registros cargados	Rango temporal (AAAAMMDD)	Observación de calidad
Affiliated_Outlets	3.583	—	Sin duplicados de clave; 626 outlets con “tamaño m2” N.D.
Product	60 (59 únicos)	—	1 código duplicado con formato contradictorio
SalesDay	1.048.575	20150309 – 20150906	Truncada al límite de filas de Excel
DeliveryDay	615.141	20150309 – 20151016	1.445 registros con unidades negativas
OoSDay	262.278	20150309 – 20151004	Afecta a 3.440 de 3.583 outlets (96%)
RouteDay	94.858	20150309 – 20151211	Cubre 3.576 de 3.583 outlets

Tabla 5.1. Volumen real y calidad de las hojas del repositorio integrado. Elaboración propia a partir de *Altadis_Dataset_Unificado.xlsx*.

Incidencias críticas detectadas

- **Truncamiento de las ventas:** la hoja SalesDay contiene exactamente 1.048.575 filas, que coincide con el número máximo de filas de una hoja de cálculo de Excel (1.048.576 incluyendo cabecera). El alcance documentado del proyecto con los primeros datos proporcionados es limitado, cubren la ventana del 9 de marzo al 6 de septiembre de 2015. En consecuencia, los totales y porcentajes de ventas de este apartado deben leerse como representativos de dicha ventana, no del año completo. Para el análisis definitivo se recomienda trabajar sobre los CSV originales o sobre el Data Warehouse en SQL, no sujetos a esta restricción.
- **Duplicado con conflicto de formato:** el catálogo declara 60 productos, pero existen 59 códigos únicos. El código Natu122 aparece dos veces con el mismo tamaño (283) pero con formato contradictorio: una fila lo clasifica como ATA y otra como ASL. Esta inconsistencia debe resolverse antes de cualquier agregación por formato, ya que distorsionaría el reparto entre categorías.

- **Registros negativos:** SalesDay incluye 148 registros con unidades negativas (mínimo -15, suma de -366 unidades) y DeliveryDay presenta 1.445 entregas negativas (mínimo -345). Responden con toda probabilidad a devoluciones, anulaciones y correcciones operativas. Se han excluido del cómputo de volumen de venta y entrega, pero se conservan para un eventual análisis de devoluciones.
- **Tamaño no disponible:** 626 de los 3.583 puntos de venta (17,5%) tienen el campo Tam_m2 informado como N.D. El tamaño del local es una variable potencialmente predictora, por lo que esta ausencia debe gestionarse de forma explícita (imputación, categoría propia o exclusión justificada) y no ignorarse.
- **Cobertura del catálogo:** 8 de los 59 productos del catálogo no registran ninguna venta en la ventana disponible y 1 outlet no presenta ventas. La integridad referencial, en cambio, es íntegra: el 100% de las transacciones de venta enlaza correctamente con un outlet y un producto existentes, lo que valida el esquema de uniones LEFT JOIN diseñado.

7.2. Caracterización de la red de puntos de venta

La red afiliada está compuesta por 3.583 estancos repartidos en ocho tipologías de ubicación. La categoría genérica ANY y los entornos de tipo VILLAGE concentran la mayor parte de la red, mientras que las ubicaciones de carácter turístico o de ocio (VACATIONAL, LEISURE, ESCAPE) son minoritarias en número pero, como se verá, relevantes en comportamiento de consumo.

Tipo de ubicación	Nº outlets	% de la red	Uds. vendidas / outlet
ANY	1.078	30,1%	670
VILLAGE	1.024	28,6%	607
CITY	416	11,6%	494
COUNTRYSIDE	380	10,6%	285
BORDER	361	10,1%	932
ESCAPE	140	3,9%	329

VACATIONAL	94	2,6%	732
LEISURE	90	2,5%	419

Tabla 5.2. Distribución de la red por ubicación e intensidad media de venta (ventana disponible 2015). Elaboración propia.




Figura 5.1. Unidades vendidas por outlet según tipo de ubicación. Destacadas en naranja las dos ubicaciones más productivas (BORDER y VACATIONAL).

Lectura de negocio. Aunque BORDER solo representa el 10% de la red, es con diferencia la ubicación más productiva por punto de venta (932 unidades/outlet, frente a una media de la red en torno a 600), un patrón coherente con el consumo transfronterizo y las compras de no residentes. VACATIONAL es la segunda más intensa (732 uds/outlet) pese a ser la categoría más pequeña. En el extremo opuesto, COUNTRYSIDE combina muchos puntos de venta con baja intensidad (285 uds/outlet), lo que abre una pregunta logística directa: si estas zonas reciben una frecuencia de visita proporcional a su número y no a su volumen, existe margen de optimización de rutas.

Nivel de vinculación comercial (Engage)

La variable Engage clasifica los outlets en tres niveles de vinculación. Su relación con las ventas es monótona y muy marcada: el nivel de engagement explica buena parte de la heterogeneidad de la red.

Nivel de Engage	Nº outlets	Uds. vendidas / outlet	Índice (Engage 1 = 100)
1 — bajo	453	135	100
2 — medio	2.461	533	395
3 — alto	669	1.155	856

Tabla 5.3. Ventas medias por nivel de engagement comercial. Elaboración propia.




Figura 5.2. Intensidad de venta por outlet según nivel de engagement comercial.

Un outlet de engagement alto vende, en promedio, 8,5 veces más unidades que uno de engagement bajo. Esta variable es, por tanto, una de las candidatas más sólidas como predictor en el modelo de ventas y como criterio de segmentación comercial: confirma que la inversión en vinculación del punto de venta tiene un correlato directo en el volumen.

Concentración de la red (análisis de Pareto). La distribución del volumen entre outlets muestra una concentración apreciable, aunque no extrema: el 20% de los puntos de venta más activos genera el 47,5% de las unidades vendidas, y el 10% superior concentra el 29,6%. Esta estructura justifica una atención comercial diferenciada y permite priorizar el suministro hacia los outlets de mayor rentabilidad histórica, tal y como plantea el análisis de venta perdida del proyecto.




Figura 5.3. Curva de concentración (Pareto) del volumen de ventas entre los puntos de venta.

7.3. Análisis de ventas por producto y formato

En la ventana disponible se contabilizan 2.146.559 unidades vendidas (excluidas las correcciones negativas). Su reparto por los tres formatos estratégicos descritos en el apartado anterior confirma el papel de cada categoría dentro del portafolio.

Formato	Descripción	% unidades vendidas	Rol en el negocio
ASL	Cigarrillo tradicional (volumen)	65,8%	Motor de volumen
ETO	Liar, papel, nicotina oral, emergentes	23,5%	Crecimiento / accesorios
ATA	Premium y nuevas categorías (THP)	10,8%	Generador de valor

Tabla 5.4. Reparto de unidades vendidas por formato (ventana disponible 2015). Elaboración propia.




Figura 5.4. Reparto de las unidades vendidas entre los tres formatos estratégicos.

ASL confirma su condición de motor de volumen, con casi dos de cada tres unidades. Un dato relevante es que ETO supera a ATA en unidades (23,5% frente a 10,8%): la categoría emergente y de liar mueve más volumen físico que la premium, lo que es esperable dado que ATA aporta valor por margen y no por cantidad. Esta asimetría volumen/valor es precisamente la que justifica tratar cada formato con una lógica de agregación distinta, tal como se anticipaba en la clasificación estratégica.

Productos de mayor rotación

Código	Formato	Unidades vendidas
Natu408	ASL	371.042
Dome206	ETO	287.553
Dome427	ASL	188.980
Natu079	ASL	143.550
Inte404	ETO	123.019

Tabla 5.5. Cinco referencias de mayor volumen de venta. Elaboración propia.

El liderazgo de Natu408 (ASL) y la fuerte presencia de Dome206 (ETO) en el top de rotación confirman que la disponibilidad de estas referencias es crítica para el KPI de volumen total: cualquier rotura sobre ellas tiene un impacto desproporcionado sobre la venta de la red.

7.4. Análisis de roturas de stock

Las roturas de stock constituyen el bloque analítico de mayor valor del proyecto, al cuantificar la indisponibilidad de producto y, por extensión, la venta perdida. En la ventana disponible se registran 262.278 eventos de Out of Stock que afectan a 3.440 de los 3.583 outlets, es decir, al 96% de la red, con una media de 76 eventos por outlet afectado. La rotura no es, por tanto, un fenómeno marginal ni localizado, sino una característica estructural de la operativa.

El hallazgo central: sobrerrepresentación del formato premium

Al cruzar la cuota de cada formato en ventas con su cuota en roturas emerge el hallazgo más significativo del análisis descriptivo:

Formato	% de unidades vendidas	% de eventos OoS	Índice de sobre/infrarrepresentación
ATA (premium)	10,8%	32,6%	3,0× — fuertemente sobrerrepresentado
ASL (volumen)	65,8%	56,8%	0,9× — ligeramente infrarrepresentado
ETO (emergente)	23,5%	10,6%	0,5× — infrarrepresentado

Tabla 5.6. Comparación entre cuota de ventas y cuota de roturas por formato. Elaboración propia.




Figura 5.5. Cuota de ventas frente a cuota de roturas por formato. El formato premium ATA sufre tres veces más roturas de las que le correspondería por su peso comercial.

Interpretación. El formato ATA, que apenas representa el 10,8% de las unidades vendidas, concentra el 32,6% de las roturas de stock: sufre tres veces más incidencias de las que le corresponderían por su peso comercial. Esto valida empíricamente la hipótesis planteada en la clasificación estratégica de productos, según la cual la falta de stock en el segmento premium no solo supone una venta perdida puntual, sino que daña la imagen de exclusividad y disponibilidad de marcas como Davidoff o las nuevas categorías THP. El formato ETO, en cambio, está claramente infrarrepresentado en roturas, lo que sugiere una gestión de aprovisionamiento más holgada o una demanda más predecible. El corolario operativo es claro: la política de reposición debería ser diferenciada por formato, priorizando la fiabilidad de servicio del segmento ATA por encima de lo que indicaría su mero volumen.

Productos y zonas más afectados

Las referencias con mayor número de eventos de rotura son Natu122 (ATA, 32.500 eventos), Dome363 (ASL, 28.284), Dome164 (ASL, 23.319), Dome615 (ASL, 23.049) e Inte615 (ATA, 14.042). La presencia de dos referencias ATA entre las cinco más problemáticas refuerza el diagnóstico anterior.

Geográficamente, las roturas se concentran en las ubicaciones ANY (29,3%) y VILLAGE (26,5%), en línea con su peso en la red, pero merece seguimiento el caso de CITY, que acumula un 14,2% de las roturas frente a un 9,6% de las ventas, posible indicio de una reposición urbana insuficiente respecto a su rotación.

7.5. Cadena de suministro: entregas y cobertura de rutas

El cruce entre entregas y ventas permite evaluar el ajuste entre suministro y demanda. Restringiendo ambas series a la ventana temporal común (hasta el 6 de septiembre de 2015) para una comparación homogénea, se entregaron 4,3 millones de unidades frente a 2,1 millones vendidas, lo que arroja un ratio entrega/venta global en torno a 2,0 y una mediana por producto de 2,4. Este resultado apunta a un colchón de inventario considerable en la red y debe interpretarse con cautela: parte del exceso es inventario en tránsito o stock de seguridad legítimo, pero un ratio sostenido de esa magnitud, conviviendo con un 96% de outlets que sufren roturas, sugiere un problema de distribución del stock más que de volumen agregado. En otras palabras, no parece faltar producto en la red, sino que este no siempre está en el punto de venta correcto en el momento adecuado.

En cuanto a la cobertura comercial, la hoja RouteDay registra 94.858 visitas que alcanzan a 3.576 de los 3.583 outlets (prácticamente la totalidad de la red), con una media de 26,5 visitas por punto de venta en el período. Cruzar esta frecuencia de visita con el volumen de ventas y la incidencia de roturas por tipo de ubicación es la vía directa para detectar las ineficiencias logísticas que el proyecto busca corregir: por ejemplo, contrastar si las zonas COUNTRYSIDE —de baja intensidad de venta— reciben una frecuencia de visita superior a la que justificaría su rotación.

7.6. Patrones temporales y estacionalidad semanal

El análisis del calendario de ventas revela un patrón semanal nítido. El domingo es, con enorme diferencia, el día de menor actividad (apenas 55.868 unidades frente a más de 300.000 en cualquier día laborable), reflejo directo del cierre dominical de la mayoría de

los estancos. El lunes es el día de mayor venta (393.672 unidades), seguido del viernes (376.418) y el sábado (351.924), mientras que la franja central de la semana (martes a jueves) presenta los registros más bajos dentro de los días laborables.

Día de la semana	Unidades vendidas	Lectura
Lunes	393.672	Pico semanal (reposición tras fin de semana)
Viernes	376.418	Segundo pico (víspera de fin de semana)
Sábado	351.924	Alto
Martes	331.815	Valle laborable
Miércoles	325.522	Valle laborable
Jueves	311.340	Mínimo laborable
Domingo	55.868	Cierre generalizado

Tabla 5.7. Distribución de las ventas por día de la semana (ventana disponible 2015). Elaboración propia.




Figura 5.6. Patrón semanal de ventas. Destacados en azul oscuro los dos picos (lunes y viernes) y en gris el mínimo dominical.

Este patrón tiene implicaciones logísticas directas: concentrar la reposición a comienzos de semana y antes del fin de semana ayudaría a prevenir las roturas en los picos de demanda de lunes y viernes. La construcción de una tabla calendario que incorpore festivos, puentes y estación del año —prevista en el modelo de datos— permitirá afinar este análisis y alimentar las variables temporales del modelo predictivo.

7.7. Síntesis y conexión con la fase de modelización

El análisis exploratorio confirma que el repositorio integrado, pese a las limitaciones de calidad documentadas, sostiene un análisis de negocio sólido. Los hallazgos principales pueden resumirse así:

- **Heterogeneidad estructural** — la red es heterogénea y su volumen está concentrado: el engagement comercial y la tipología de ubicación (especialmente BORDER y VACATIONAL) explican gran parte de las diferencias de venta entre outlets.
- **La rotura es sistémica y desequilibrada** — el 96% de los outlets sufre roturas y el formato premium ATA está sobrerrepresentado en ellas (3×), lo que exige una política de reposición diferenciada por formato y orientada al servicio, no solo al volumen.
- **Distribución antes que volumen** — el elevado ratio entrega/venta conviviendo con roturas generalizadas señala un problema de asignación del stock dentro de la red, no de escasez agregada.
- **Estacionalidad aprovechable** — existe un patrón semanal robusto (picos en lunes y viernes, cierre dominical) que debe incorporarse a la planificación de reposición y al modelo de previsión.

Estos resultados delimitan las variables candidatas para la fase predictiva: nivel de engagement, tipo de ubicación, formato de producto, día de la semana, histórico de ventas, volumen entregado e incidencia previa de roturas.

Sobre ellas se construyó el dataset de entrenamiento de los modelos de clasificación para predicción de rotura de stock (Regresión Logística, Árbol de Decisión y XGBoost), descritos en el apartado de modelos predictivos, y se alimentaron los cuadros de mando de Power BI dirigidos a los perfiles directivos de Imperial Brands.

8. ANÁLISIS DE LA CALIDAD Y CONSISTENCIA DE LOS DATOS

8.1. Metodología de auditoría

Antes de construir el Data Warehouse y lanzar cualquier análisis, se realizó una auditoría sistemática de las seis fuentes de datos proporcionadas por Altadis. El objetivo era conocer de primera mano el estado real de los datos: cuántos registros hay, qué periodo cubren y qué problemas presentan. Este paso es imprescindible en cualquier proyecto de Business Intelligence porque los errores que no se detectan en origen se propagan a todos los análisis posteriores y contaminan los resultados.

La siguiente tabla resume el volumen y las principales observaciones de calidad detectadas en cada fichero:

Hoja	Registros cargados	Rango temporal (AAAAMMDD)	Observación de calidad
Affiliated_Outlets	3.583	—	Sin duplicados de clave; 626 outlets con tamaño N.D.
Product	60 (59 únicos)	—	1 código duplicado (Natu122) con formato contradictorio; resuelto en TablaMaestra5
SalesDay	1.048.575	20150309 – 20150906	Truncada al límite de filas de Excel
DeliveryDay	615.141	20150309 – 20151016	1.445 registros con unidades negativas
OoSDay	262.278	20150309 – 20151004	Afecta a 3.440 de 3.583 outlets (96%)
RouteDay	94.858	20150309 – 20151211	Cubre 3.576 de 3.583 outlets

Tabla 1. Volumen real y calidad de las hojas del repositorio integrado. Elaboración propia.

8.2. Incidencias detectadas y tratamiento aplicado

8.2.1. Truncamiento de SalesDay

La hoja SalesDay contiene exactamente 1.048.575 filas, cifra que coincide con el número máximo de filas de una hoja de cálculo de Excel (1.048.576 incluyendo cabecera), lo que indica que el fichero original estaba truncado al exportarse. El periodo de ventas disponible queda acotado a la ventana del 9 de marzo al 6 de septiembre de 2015.

En consecuencia, todos los totales y porcentajes de ventas calculados sobre esta fuente deben leerse como representativos de esa ventana, no del año fiscal completo. El resto de tablas cubre periodos más amplios: DeliveryDay llega hasta octubre de 2015 y RouteDay hasta diciembre, lo que genera una asimetría temporal entre fuentes que se ha tenido en cuenta al diseñar los cruces.

8.2.2. Registros negativos en ventas y entregas

SalesDay incluye 148 registros con unidades de venta negativas (mínimo -15, suma de -366 unidades) y DeliveryDay presenta 1.445 entregas negativas (mínimo -345), que responden con toda probabilidad a devoluciones, anulaciones y correcciones operativas. Para el análisis de volúmenes se han excluido del cómputo principal, pero se conservan en la tabla integrada como información de contexto para un eventual análisis de devoluciones.

8.2.3. Duplicado con conflicto de formato en Product

El catálogo declara 60 productos, pero existen 59 códigos únicos. El código Natu122 aparece dos veces con el mismo tamaño (283) pero con formato contradictorio: una fila lo clasifica como ATA y otra como ASL. Ante la imposibilidad de contrastar con la fuente original, se ha optado por conservar el registro con Format = "ATA", al ser el formato menos frecuente en el catálogo y, por tanto, más probable que el duplicado en ASL corresponda a un error de entrada de datos. Esta limpieza se ha resuelto mediante una expresión de tabla común (CTE) con la función ROW_NUMBER(), que selecciona de forma determinista y documentada el registro ATA antes de construir cualquier tabla integrada, evitando así la duplicación de ventas de este producto en los análisis posteriores.

8.2.4. Tamaño no disponible en Affiliated_Outlets

626 de los 3.583 puntos de venta (17,5%) tienen el campo Tam_m2 informado como N.D. El tamaño del local es una variable potencialmente predictora, por lo que esta

ausencia debe gestionarse de forma explícita en fases posteriores del análisis y no ignorarse. En fases posteriores del análisis se gestionará mediante imputación, creando una categoría propia para los valores no disponibles o excluyéndolos de los modelos donde el tamaño sea una variable relevante.

8.2.5. Cobertura de roturas de stock

OoSDay registra incidencias en 3.440 de los 3.583 establecimientos (96% de cobertura). Sin embargo, al ser un registro declarativo, su calidad depende de que el encargado de cada estanco notifique activamente la rotura. La combinación de una tasa de notificación alta a nivel de establecimiento con una tasa baja de días con rotura efectivamente registrada (841 días sobre más de un millón de combinaciones día-estanco-producto) sugiere que muchos estancos declaran ocasionalmente pero no de forma sistemática. Este sesgo de subnotificación es una limitación conocida del dato: las cifras de rotura deben interpretarse como un límite inferior del fenómeno real, no como su medida exacta.

8.2.6. Integridad referencial

El 100% de las transacciones de venta en SalesDay enlaza con un outlet existente en Affiliated_Outlets y con un producto existente en Product, lo que valida el esquema de uniones LEFT JOIN utilizado para construir la tabla integrada y garantiza que no hay registros huérfanos que distorsionen los análisis de cruce.

8.2.7. Cobertura del catálogo: productos sin venta registrada

8 de los 59 productos del catálogo no registran ninguna venta en la ventana disponible de SalesDay. Un análisis adicional contrastando estos 8 códigos contra DeliveryDay permite distinguir dos fenómenos distintos dentro de este grupo, en lugar de tratarlo como una categoría homogénea:

- Sin entrega ni venta (Dome575, Inte657, Inte755): estos 3 productos no aparecen tampoco en DeliveryDay durante la ventana observada. El

producto no circuló en ningún momento del periodo, lo que apunta a descatalogación o a un lanzamiento posterior a la ventana truncada de SalesDay, más que a un problema de truncado.

- Entrega sin conversión a venta (Dome019, Dome586, Dome770, Don122, Inte190): estos 5 productos sí registran entregas (entre 1 y 8 movimientos), pero cero ventas. El caso de Don122 es el más significativo: sus 8 entregas se distribuyeron entre 8 estancos distintos, lo que descarta un error puntual de un solo punto de venta y refuerza la hipótesis de un producto en fase de prueba de distribución que todavía no ha generado conversión a venta dentro de la ventana truncada de 7 meses.

Adicionalmente, 1 outlet no presenta ventas en el periodo. En conjunto, estos hallazgos no representan un problema de calidad en sí mismos, sino una característica del periodo analizado que conviene documentar y tener presente al interpretar cualquier segmentación por producto.

8.3. Conclusión de la auditoría de calidad


En conjunto, los datos presentan una calidad suficiente para construir análisis robustos, siempre que se apliquen los filtros y correcciones descritos. Las limitaciones más relevantes son el truncado de SalesDay, que acota el análisis de ventas a siete meses, y la subnotificación en OoSDay, que hace que las cifras de rotura de stock deban interpretarse como un límite inferior del fenómeno real. Todas las correcciones identificadas en esta fase exclusión de unidades negativas, resolución del duplicado de Natu122 y distinción entre productos sin movimiento se han incorporado de forma sistemática en la construcción del Data Warehouse construido para este TFM, el cual se describe en el siguiente apartado

9. DISEÑO E IMPLEMENTACIÓN DEL DATA WAREHOUSE

9.1. Arquitectura del modelo dimensional

Siguiendo la metodología de Kimball, el modelo de datos se ha diseñado como un esquema en estrella en el que la actividad de venta se modela como tabla de hechos (FACT_Ventas), conectada a tres dimensiones de análisis: DIM_Producto, DIM_Outlet y DIM_Fecha. Las claves de Affiliated_Code, Product_Code y Sales_DAY presentes en SalesDay son las únicas que permiten cruzar simultáneamente la actividad comercial con la información descriptiva del producto, del punto de venta y del calendario, por lo que SalesDay se ha tomado como base de la tabla de hechos.

Para la variable de renta media provincial, se evaluó la posibilidad de modelarla como una dimensión geográfica independiente (DIM_Geografia) en un esquema en copo de nieve (snowflake). Se descartó esta opción: al disponer del dato únicamente a nivel provincia (52 valores distintos para 3.583 outlets), la dimensión secundaria no alcanza volumen ni reutilización suficiente para justificar la complejidad adicional de una tabla separada. Se optó en su lugar por incorporar la renta media provincial directamente como atributo de DIM_Outlet, siguiendo el principio de desnormalización controlada propio de los esquemas en estrella de Kimball.



Esquema en estrella - Proyecto Altadis Imperial Brands - Elaboración propia

9.2. Construcción de la tabla integrada (staging)

Como paso previo a la separación formal de hechos y dimensiones, se construyó en SQL Server una tabla integrada de staging (TablaMaestra5) que materializa el cruce completo de las seis fuentes en una única estructura de consulta, útil tanto para la validación de calidad como para los análisis exploratorios iniciales.

La construcción se realizó en los siguientes pasos:

- Resolución del duplicado de Product mediante un CTE con ROW_NUMBER(), que garantiza una única fila por Product_Code (Natu122 resuelto como ATA, al ser el formato menos frecuente en el catálogo y, por tanto, más probable que el duplicado en ASL correspondiera a un error de entrada de datos) antes de cualquier unión.
- Unión de SalesDay con Affiliated_Outlets_Enriched y con el producto ya depurado, mediante LEFT JOIN sobre las claves Affiliated_Code y Product_Code respectivamente.
- Incorporación de tres columnas calculadas: Delivery_Unidades (unidades entregadas el mismo día, agregadas desde DeliveryDay), Flag_OoS (rotura de stock declarada) y Flag_Ruta (ruta de reparto programada).
- Resolución de una incompatibilidad de tipos de datos entre tablas (fechas como número decimal en unas fuentes y como tipo fecha en otras), mediante conversiones explícitas con CONVERT/CAST.

Una decisión técnica relevante fue sustituir las subconsultas correlacionadas inicialmente empleadas para calcular Delivery_Unidades, Flag_OoS y Flag_Ruta por actualizaciones basadas en LEFT JOIN, dado que las subconsultas correlacionadas resultan inviables en tiempo de ejecución sobre más de un millón de filas.

9.3. Validación de la tabla integrada

Indicador	Valor	Sobre el total de
Filas totales	1.048.575	—
Productos únicos	51	59 del catálogo
Días con rotura declarada (Flag_OoS = 1)	841	1.048.575
Registros con ruta programada (Flag_Ruta = 1)	118.960	1.048.575
Registros con entrega el mismo día	99.706 (9,5%)	1.048.575

Tabla 1. Indicadores de validación sobre TablaMaestra5. Elaboración propia.

Los 841 días con rotura y los 118.960 registros con ruta coinciden exactamente con las cifras obtenidas de forma independiente sobre las fuentes originales, confirmando que la integración se realizó correctamente. El indicador de 51 productos únicos sobre 59 del catálogo es coherente con los 8 productos sin venta identificados en la auditoría de calidad, confirmando que la diferencia responde a una característica real del periodo y no a un defecto de construcción. El 9,5% de coincidencia de entregas el mismo día es coherente con la frecuencia media de reposición declarada en el briefing (aproximadamente cada 10 días).

9.4. Integración de variables externas agregadas

9.4.1. Enriquecimiento geográfico: incorporación de la variable Provincia

Para enriquecer la dimensión de outlet con información geográfica, se incorporó la variable Provincia mediante el cruce de Affiliated_Outlets con una tabla de códigos postales por provincia obtenida del INE (CodPostalesProvincias), que recoge la

correspondencia entre los dos primeros dígitos del código postal (CPRO) y el nombre de la provincia para el conjunto de las 52 provincias españolas.

Durante la preparación del cruce se detectó una incompatibilidad de formato: el campo POSTALCODE de Affiliated_Outlets se almacenaba como valor numérico, perdiendo el cero inicial en los códigos postales de provincias de un solo dígito (por ejemplo, 3801 en lugar de 03801 para Alicante, u 8134 en lugar de 08134 para Barcelona). Una verificación sobre el conjunto completo de outlets confirmó que 761 de los 3.583 registros (21,2%) presentaban esta circunstancia, una proporción suficientemente relevante como para invalidar cualquier análisis geográfico si no se corregía antes del cruce.

La incidencia se resolvió normalizando el código postal a cinco dígitos mediante una conversión explícita en SQL (rellenando con cero a la izquierda antes de extraer los dos primeros caracteres), garantizando la correspondencia correcta con la tabla de provincias del INE. El resultado se materializó en la tabla AffiliatedOutlets_Enriched, que incorpora la columna PROVINCIA junto al resto de atributos originales del outlet.

9.4.2. Tratamiento de valores faltantes en la variable Renta_Media_Provincial

La fuente utilizada para enriquecer la dimensión de outlet con información socioeconómica ha sido la serie Renta neta media por persona del INE, a nivel provincial. Al consultar el año 2015 (coincidente con la ventana temporal de los datos operacionales de Altadis) se identificó la ausencia de valor para tres provincias: Gipuzkoa, Araba/Álava y Navarra.

Para Gipuzkoa se localizó el dato correspondiente a 2016 (15.090 €), actualizado a precios de 2015 aplicando la variación del Índice de Precios de Consumo (IPC) general entre diciembre de 2015 y diciembre de 2016 (1,6%, verificado mediante la calculadora oficial del INE), resultando en un valor ajustado de 14.852,36 €.

Para Álava y Navarra no se localizó ningún valor anterior a 2023 (17.806 € y 16.423 € respectivamente). Dado el desfase de ocho años, se aplicó la misma metodología de deflatación por IPC general (variación diciembre 2015–2023: 21,0%, verificada en la misma fuente oficial), obteniendo valores ajustados de 14.715,70 € para Araba/Álava y 13.572,73 € para Navarra.

Esta aproximación asume que la posición relativa de cada provincia en la distribución de renta se mantiene razonablemente estable en el periodo. Una vez deflactados, los tres valores resultantes quedan en un rango coherente con el de provincias de perfil socioeconómico similar ya disponibles para 2015 (Bizkaia: 13.949 €; Madrid: 13.779 €), lo que respalda la razonabilidad de la aproximación adoptada.

9.4.3. Incorporación del calendario de festivos de España

La última fuente externa incorporada al modelo es el calendario de festivos laborales de España para 2015, sugerido en el briefing como variable de enriquecimiento temporal. La fuente utilizada ha sido la Resolución de 17 de octubre de 2014 de la Dirección General de Empleo (BOE-A-2014-10823), que detalla los festivos de ámbito nacional y los específicos de cada Comunidad Autónoma.

A diferencia de Provincia y Renta_Media_Provincial, el calendario de festivos no puede tratarse como un atributo fijo del outlet, ya que su valor depende simultáneamente de la fecha y del territorio: una misma fecha puede ser festivo en una Comunidad Autónoma y laborable en otra. Por ello, Es_Festivo se construyó cruzando la fecha de venta, la provincia del outlet y la Comunidad Autónoma a la que pertenece, para lo cual se creó una tabla auxiliar (Provincia_CCAA) que asocia cada provincia con su Comunidad Autónoma, validada sin huérfanos contra las provincias reales de TablaMaestra5.

Dado que SalesDay queda acotada a la ventana de 9 de marzo a 6 de septiembre de 2015, se generó una vista (Festivos_2015_VentanaVentas) que filtra el calendario completo a las 14 fechas festivas que caen dentro de dicho periodo, conservando la tabla completa de 24 fechas para un eventual uso futuro sobre DeliveryDay o RouteDay, cuyas ventanas temporales son más amplias.

El resultado señala que 35.670 de los 1.048.575 registros de TablaMaestra5 (3,4%) corresponden a una venta registrada en fecha festiva para la Comunidad Autónoma del outlet correspondiente, sin alteración del número total de filas, lo que confirma la ausencia de duplicados introducidos por el cruce.

9.5. Materialización del modelo dimensional: extracción de FACT y DIM

Una vez incorporadas a TablaMaestra5 todas las variables de enriquecimiento, se materializó el esquema en estrella diseñado al inicio del proyecto, separando físicamente la tabla integrada en sus componentes de hechos y dimensiones. Este paso resuelve la limitación de TablaMaestra5: aun siendo válida para la validación de calidad, constituye una tabla desnormalizada y no un modelo multidimensional en sentido estricto, al repetir los atributos de outlet y producto en cada uno de los más de un millón de registros de venta.

Tabla	Filas	Descripción
DIM_Producto	59	Catálogo completo de productos, con Natu122 resuelto.
DIM_Outlet	3.583	Catálogo completo de outlets, con provincia y renta media provincial incorporadas.
DIM_Fecha	182	Calendario diario de la ventana real de SalesDay, con atributos de calendario e indicador de festivo nacional.
FACT_Ventas	1.048.575	Claves foráneas a las tres dimensiones y métricas de venta, entrega, rotura, ruta y festivo (detalle autonómico).

Tabla 2. Tablas físicas del modelo dimensional final. Elaboración propia.

Una decisión relevante de este proceso fue reconstruir DIM_Producto y DIM_Outlet a partir de las tablas fuente originales (Product y AffiliatedOutlets_Enriched) en lugar de extraerlas mediante SELECT DISTINCT sobre TablaMaestra5. Una primera versión de DIM_Outlet, construida sobre TablaMaestra5, arrojó 3.582 outlets en lugar de los 3.583 reales, omitiendo el único outlet sin ventas identificado en la auditoría de calidad. Este hallazgo confirmó que extraer dimensiones desde la tabla de hechos introduce un sesgo de supervivencia: cualquier entidad sin actividad registrada desaparece silenciosamente de la dimensión. Por ello, ambas dimensiones se reconstruyeron desde las tablas origen completas.

Como consecuencia, DIM_Outlet y DIM_Producto contienen entidades sin hechos asociados en FACT_Ventas (el outlet sin ventas y los 8 productos sin movimiento). Esto no constituye un error de integridad, sino el comportamiento esperado en un esquema en estrella correctamente normalizado. Se ha verificado que la relación inversa es completa: el 100% de los registros de FACT_Ventas referencia un outlet, un producto y una fecha existentes en sus dimensiones, sin huérfanos en ninguna dirección.

El indicador de festivo se modeló de forma diferenciada entre DIM_Fecha y FACT_Ventas: DIM_Fecha incorpora únicamente Es_Festivo_Nacional (compatible con el grano de una dimensión de fecha pura), mientras que FACT_Ventas hereda de TablaMaestra5 el indicador Es_Festivo con el detalle autonómico completo, evitando forzar un atributo dependiente del territorio dentro de una dimensión que, por diseño, no lo contempla.

9.6. Cierre del objetivo 2

Con la materialización de las cuatro tablas descritas, el proyecto dispone de un modelo dimensional completo en esquema en estrella: una tabla de hechos (FACT_Ventas) conectada a tres dimensiones (DIM_Producto, DIM_Outlet, DIM_Fecha) mediante claves foráneas verificadas sin huérfanos en ninguna dirección.

TablaMaestra5 se conserva como herramienta de staging y validación de calidad, mientras que el análisis y la explotación posterior del proyecto (dashboard de KPIs y modelos predictivos) se apoyarán sobre el modelo dimensional aquí descrito.

	Total_Registros	Outlets_Unicos	Productos_Unicos	Fecha_Min	Fecha_Max	Unidades_Vendidas_Total	Dias_Con_Rotura	Dias_Con_Ruta	Dias_Con_Entrega
1	1048575	3582	51	20150309	20150906	2146559	841	118960	99706

	Total_Registros	Outlets_Unicos	Productos_Unicos	Fecha_Min	Fecha_Max
1	1048575	3582	51	20150309	20150906

Unidades_Vendidas_Total	Dias_Con_Rotura	Dias_Con_Ruta	Dias_Con_Entrega
2146559	841	118960	99706

Figura 6. Vista del cuadro de mando Power BI y de la tabla integrada (staging) TablaMaestra5.

Elaboración propia.

10. CLUSTERIZACIÓN DE OUTLETS

10.1. Planteamiento y alcance

El objetivo 4 del proyecto contempla el desarrollo de modelos y algoritmos de predicción de ventas/demanda/rupturas de stock y de clusterización de datos. Dado el volumen de trabajo que implican tres modelos completos, se decidió repartir el esfuerzo según la naturaleza de cada tarea: la clusterización de outlets se aborda en Python (scikit-learn), por ser el problema más directo de preparar con los datos ya disponibles en el Data Warehouse; la predicción de rotura de stock se plantea como un problema de clasificación binaria, también en Python; y la predicción de demanda, al ser una serie temporal más sensible a la ventana truncada de los datos, se reserva para R.

Este apartado documenta la primera de las tres piezas: la segmentación de outlets mediante k-means.

10.2. Selección y preparación de variables

Se descartó utilizar únicamente atributos estáticos del outlet (provincia, tamaño, renta), ya que un clustering construido solo con variables descriptivas agruparía outlets por parecido demográfico, no por comportamiento de negocio. Para que la segmentación tuviera utilidad práctica, se enriqueció cada outlet con tres métricas agregadas desde FACT_Ventas: volumen total de venta, tasa de rotura de stock y número de productos distintos vendidos.

Las cinco variables finales empleadas en el clustering fueron: Tam_m2_Numerico, Renta_Media_Provincial, Ventas_Totales, Tasa_Rotura y Num_Productos_Distintos. Se excluyeron Provincia (alta cardinalidad y parcialmente redundante con la renta provincial) y Location, que se conservó como variable de caracterización cualitativa posterior, sin formar parte del algoritmo de agrupamiento.

10.3. Codificación de la variable Tam_m2

La variable de tamaño del local se almacena en el Data Warehouse como una categoría ordinal de texto (por ejemplo, 5-10m², >20m²), por lo que requirió una conversión a valor numérico antes de poder utilizarse en el clustering. Cada categoría cerrada se codificó como el punto medio de su intervalo (2-5m² → 3,5; 5-10m² → 7,5, etc.), y las categorías abiertas se codificaron con un valor convencional próximo al límite conocido.

Durante esta conversión se detectó una incoherencia en el catálogo de categorías: la etiqueta >20m² (164 outlets, el 4,6% del total) coexiste con las categorías más finas 20-30m² y >30m², que parecen corresponder a una revisión posterior del criterio de clasificación sin reasignar los registros previamente etiquetados con el criterio anterior. Ante la imposibilidad de verificar a qué tramo correspondería cada uno de esos 164 outlets, se les asignó un valor numérico de 26, próximo a la categoría 20-30m², como aproximación declarada y no como medición exacta. Esta limitación se señala explícitamente y no se oculta en el análisis.

Los 626 outlets (17,5% del total) con tamaño no disponible (N.D.) se excluyeron del análisis de clustering, en lugar de imputar un valor estimado, para evitar introducir un

sesgo artificial hacia el centro de la distribución en una variable determinante para la composición de los grupos. El análisis de clustering se realizó, por tanto, sobre los 2.957 outlets con tamaño conocido.

10.4. Estandarización y elección del número de clusters

Las cinco variables se estandarizaron (media 0, desviación 1) antes de aplicar k-means, dado que se encuentran en escalas muy distintas: la renta provincial se mide en miles de euros, mientras que la tasa de rotura es un decimal entre 0 y 1. Sin esta estandarización, la renta dominaría por completo la distancia euclídea utilizada por el algoritmo.

Para justificar el número de clusters de forma objetiva, se evaluaron los valores de k entre 2 y 8 mediante el método del codo (inercia) y el coeficiente de silueta (silhouette score).




Figura 1. Método del codo y coeficiente de silueta para k=2 a 8. Elaboración propia.

El silhouette score máximo se alcanza en k=7 (0,254), pero la diferencia frente a k=5 (0,233) es reducida. Se optó por k=5, al resultar un número de grupos más manejable para la interpretación de negocio y la presentación de resultados, sin pérdida sustancial de calidad del agrupamiento respecto al óptimo estricto.

10.5. Detección y tratamiento de un cluster degenerado

Una primera ejecución de k-means con k=5 sobre el conjunto completo de 2.957 outlets produjo cuatro clusters de tamaño razonable (761, 729, 1.095 y 367 outlets) y un quinto cluster de únicamente 5 observaciones. Un grupo de solo 5 elementos sobre casi 3.000 no constituye un segmento de negocio, sino un indicio de outliers extremos que el algoritmo aísla en su propio grupo.

La inspección de esos 5 outlets reveló que su tasa de rotura de stock se sitúa entre 0,052 y 0,086, frente a una media general de 0,0009 en el conjunto completo de outlets — entre 55 y 93 veces superior. Se trata de un hallazgo cualitativo relevante por sí mismo (outlets con un problema de suministro extremo y aislado, repartidos entre las provincias de Cuenca, Pontevedra, Toledo y Murcia, sin un patrón geográfico evidente), pero su reducido tamaño muestral impide tratarlo como un segmento de negocio dentro del clustering principal.

Se excluyeron estos 5 outlets del análisis y se repitió el proceso sobre los 2.952 restantes, confirmando que k=5 seguía siendo una elección razonable (silhouette=0,237) sin que ningún cluster resultante quedara degenerado.

10.6. Resultado final: cinco segmentos de outlet

Cluster	Outlets	Tamaño (m²)	Renta prov. (€)	Ventas	Tasa rotura	Nº productos
0	715	7,82	13.169	461,57	0,00	15,52
1	959	7,78	9.534	383,93	0,00	12,55
2	727	9,54	10.743	1.285,79	0,00	20,56
3	193	9,00	10.561	427,53	0,01	14,01
4	358	28,03	10.216	691,61	0,00	16,06

No se encuentran entradas de índice. Tabla 1. Perfil medio de cada cluster (2.952 outlets, excluidos los 5 outliers de rotura). Elaboración propia, Python/scikit-learn.




Figura 2. Distribución de los 5 clusters según tamaño, renta provincial y volumen de venta. Elaboración propia.

10.7. Interpretación de negocio de cada segmento

- Cluster 0 (715 outlets): tamaño pequeño, renta provincial alta, venta media.
- Cluster 1 (959 outlets, el más numeroso): tamaño pequeño, renta baja, venta baja y catálogo reducido — el segmento de menor rendimiento comercial de la red.
- Cluster 2 (727 outlets): venta notablemente superior al resto (casi el triple de la media) y mayor diversidad de catálogo — el segmento de mejor desempeño comercial.
- Cluster 3 (193 outlets): perfil similar al promedio general, pero con una tasa de rotura de stock más elevada que el resto de grupos, sin llegar a constituir un caso extremo.
- Cluster 4 (358 outlets): único grupo claramente diferenciado por el tamaño físico del local (28 m² de media, frente a 7-9 m² del resto), sin que ese mayor tamaño se traduzca en un volumen de venta proporcionalmente superior.

La conclusión principal del análisis es que el tamaño físico del local no es el factor que mejor explica las diferencias de rendimiento comercial entre outlets: el comportamiento de venta (volumen total y diversidad de catálogo) separa los grupos con mayor claridad que las variables puramente descriptivas como el tamaño o la renta provincial. Esto tiene una implicación de negocio directa: las decisiones de priorización comercial (por ejemplo, en campañas de activación o en la asignación de nuevas referencias de producto) deberían apoyarse más en el comportamiento de venta histórico de cada outlet que en sus características físicas o geográficas.

10.8. Predicción de rotura de stock2 — clasificación binaria)

Se planteó como problema de clasificación binaria: predecir si un registro de venta (combinación día-outlet-producto) presentará rotura de stock declarada (Flag_OoS=1) o no (Flag_OoS=0). La variable objetivo presenta un desequilibrio extremo: solo 757 casos positivos sobre 950.217 registros (0,08%), muy superior al desequilibrio moderado del ejemplo del Titanic visto en clase.

Se aplicó la misma técnica de balanceo vista en las Clases 12 y 13 (class_weight='balanced' en Regresión Logística y Árbol de Decisión; scale_pos_weight=1.253 en XGBoost). Las variables predictoras seleccionadas fueron: Es_Festivo, Flag_Ruta, Delivery_Unidades, Es_Fin_Semana, Tam_m2_Numerico, Renta_Media_Provincial, Dia_Semana y Format. Se excluyó Sales_Uds para evitar fuga de información (data leakage): la rotura es causa de una venta baja o nula, no al revés.

10.9. Análisis exploratorio previo




Figura 3. Tasa de rotura por festivo y por día de la semana. Elaboración propia.

El EDA revela que la tasa de rotura es ligeramente menor en festivos que en días laborables (posiblemente por subnotificación más intensa en esas fechas) y que martes y miércoles concentran la mayor incidencia, mientras jueves y domingo presentan las tasas más bajas.

10.10. Resultados y comparación de modelos




Figura 4. Importancia de variables — Árbol de Decisión. Elaboración propia.




Figura 5. Comparación de métricas entre los tres modelos. Elaboración propia.

Modelo	Accuracy	Precision	Recall	F1
Regresión Logística	0,6269	0,0011	0,5033	0,0021
Árbol de Decisión	0,9698	0,0084	0,3179	0,0164
XGBoost	0,8430	0,0022	0,4437	0,0045

Tabla 2. Métricas de los tres modelos sobre el conjunto de test (190.044 registros). Elaboración propia.

10.11. Interpretación y conclusiones

Los tres modelos muestran un patrón consistente: Accuracy aparentemente elevado (efecto del desequilibrio extremo 1:1.253), Recall moderado para la clase con rotura (entre 0,32 y 0,50), y Precisión prácticamente nula.

Esto no es un fallo del modelado, sino una consecuencia directa de dos limitaciones conocidas de los datos: el desequilibrio extremo de la variable objetivo y la subnotificación documentada en la auditoría de calidad — muchos estancos no declaran

sistemáticamente las roturas, por lo que el número real de incidencias es presumiblemente mayor.

El hallazgo más relevante no es el rendimiento predictivo en sí, sino la importancia de variables: Delivery_Unidades concentra el 82% de la capacidad predictiva del árbol de decisión. Esto confirma que la rotura de stock en la red de Altadis es fundamentalmente un fenómeno logístico (ausencia o insuficiencia de reposición), no de demanda ni de calendario. La implicación de negocio es directa: mejorar la predicción de roturas pasa por monitorizar y anticipar los patrones de entrega.

El mejor equilibrio entre Recall y Precision lo ofrece el Árbol de Decisión ($F1=0,016$, $Recall=0,32$). La Regresión Logística maximiza el Recall ($0,50$) pero a costa de clasificar casi la mitad de todos los registros como roturas, lo que no sería operativamente útil. XGBoost queda en un punto intermedio ($Recall=0,44$, $F1=0,005$).

10.12. Limitaciones del objetivo 4

- La variable Tam_m2 se codificó mediante aproximaciones declaradas (punto medio de intervalo), por lo que el componente de tamaño en ambos modelos debe interpretarse como una escala ordinal aproximada.
- El análisis excluye los 626 outlets sin información de tamaño (17,5%) y los 5 outlets con rotura de stock extrema, por lo que los resultados no son representativos del 100% de la red.
- El silhouette score del clustering ($0,233$) es moderado: los grupos son interpretables pero existe solapamiento natural entre perfiles de outlet.
- El rendimiento de los modelos de rotura de stock está limitado por el desequilibrio extremo de la variable objetivo ($0,08\%$ de positivos) y por la subnotificación documentada en OoSDay.
- La predicción de ventas/demanda (modelo de series temporales en R) queda pendiente de completar como tercera parte del objetivo 4.

11. INTRODUCCIÓN Y OBJETO DEL INFORME

El presente documento describe el informe de Power BI desarrollado como herramienta de análisis exploratorio y de apoyo a la toma de decisiones dentro del Trabajo de Fin de Máster, centrado en el comportamiento de ventas de la red de estancos abastecida por Altadis / Imperial Brands en el territorio español. El informe se ha construido a partir de un conjunto de datos transaccional que combina información de ventas, reposición (delivery), características del punto de venta y variables geográficas y socioeconómicas, con el fin de identificar patrones relevantes para la gestión comercial y logística del canal.

El informe se organiza en cuatro hojas o páginas de análisis, cada una orientada a una dimensión distinta del problema: una visión ejecutiva de conjunto, el análisis geográfico y de renta, el análisis de stock y logística, y el análisis de estacionalidad. Esta estructura responde a un enfoque analítico progresivo: de lo general (resumen ejecutivo) a lo particular (patrones geográficos, logísticos y temporales), permitiendo que cualquier lector del informe (tutor, tribunal o responsable de negocio) pueda situarse rápidamente y luego profundizar en el aspecto que le resulte de mayor interés.

11.1. Advertencia metodológica sobre la cobertura temporal de los datos

Antes de describir el contenido de cada hoja, es necesario señalar una limitación estructural del conjunto de datos que condiciona la interpretación de cualquier resultado: el fichero de origen se encuentra truncado en el límite máximo de filas de Excel (1.048.575 registros), lo que provoca que la cobertura real de información se limite al periodo comprendido entre el 9 de marzo y el 6 de septiembre de 2015, sin que existan meses completos ausentes, sino un corte abrupto al final de la ventana disponible. Esta circunstancia no constituye un patrón de estacionalidad genuino, sino una ausencia de información, y así se ha tratado en todo el análisis.

Por este motivo, las lecturas que se presentan a continuación se refieren siempre al periodo efectivamente cubierto por el dato, y se evita deliberadamente cualquier extrapolación de tendencias anuales o interpretación de estacionalidad mensual completa. Declarar esta limitación de forma explícita, en lugar de omitirla, se considera parte del rigor metodológico exigible a un trabajo de esta naturaleza.

11.2. Metodología de construcción

El informe se ha construido sobre un modelo de datos en estrella, con una tabla de hechos que recoge cada registro de venta y reposición, y tablas de dimensión de fecha, punto de venta (outlet/estanco) y producto. Sobre este modelo se han definido medidas de análisis mediante el lenguaje DAX, lo que permite que los indicadores mostrados en el informe (unidades vendidas, tasas de rotura de stock, medias de venta, diferenciales porcentuales, etc.) se recalculen dinámicamente en función de los filtros y segmentaciones aplicados por el usuario, en lugar de ser cifras estáticas. Esta característica es la que otorga al informe su naturaleza interactiva y de herramienta de exploración, más allá de un simple documento de reporting fijo.

12. RESUMEN EJECUTIVO

Esta primera hoja tiene como función ofrecer una fotografía global del conjunto de datos y de los principales indicadores de negocio, a modo de punto de partida para el resto del análisis. Reúne cinco tarjetas de indicador (KPI) y dos visualizaciones de apoyo.

12.1. Indicadores clave (tarjetas)

Se muestran cinco métricas de síntesis: las unidades netas vendidas en el periodo (2,147 millones de unidades), el número de estancos con actividad registrada (3.582 puntos de venta), el número de productos distintos con ventas (51 referencias), el número de registros de devolución (148) y la tasa de rotura de stock a nivel global (0,08 %). Estas

cinco cifras permiten valorar de un vistazo tanto la magnitud del negocio analizado como su calidad operativa: un volumen de ventas elevado, una red de puntos de venta amplia, un catálogo de producto acotado y unos niveles de devolución y rotura de stock reducidos, lo que sugiere una cadena de suministro razonablemente eficiente en el periodo observado.

12.2. Mix de ventas por formato

El gráfico de anillo desagrega el volumen de ventas según el formato del punto de venta, distinguiendo entre estancos ASL, ETO y ATA. El formato ASL concentra la mayor parte de las ventas (65,76 %), seguido de ETO (23,48 %) y ATA (10,76 %). Esta distribución resulta relevante porque evidencia que el negocio no está homogéneamente repartido entre tipologías de punto de venta, sino fuertemente concentrado en un formato concreto, lo que tiene implicaciones tanto comerciales (foco de la fuerza de ventas) como logísticas (dimensionamiento de las rutas de reparto en función del formato dominante).

12.3. Ventas netas por provincia

El gráfico de barras horizontales ordena las provincias españolas de mayor a menor volumen de ventas netas. Madrid encabeza claramente el ranking, seguida de Barcelona y Valencia/València, y a continuación un grupo de provincias de tamaño intermedio (Alicante, Sevilla, Cádiz, Murcia, entre otras). Esta jerarquía es coherente con la distribución poblacional y comercial del país, y sirve como referencia para contrastar, en la hoja de geografía y renta, si ese liderazgo en volumen se explica por el tamaño de la provincia o si existen provincias con menor volumen absoluto pero mayor intensidad de venta por estanco.

Un filtro de formato (ASL) situado en la parte superior de la hoja permite además al usuario aislar el análisis a un formato concreto, comprobando si la jerarquía provincial se mantiene o cambia al excluir el resto de tipologías, lo que añade una capa de análisis exploratorio propio del informe.

13. GEOGRAFÍA Y RENTA

Esta hoja profundiza en la dimensión territorial del negocio, cruzando el volumen de ventas con variables socioeconómicas y características físicas del punto de venta, con el objetivo de identificar si existe relación entre la renta de una provincia y su comportamiento de venta.

13.1. Ventas por estanco frente a renta provincial

El gráfico de dispersión relaciona, para cada provincia, la renta provincial (eje horizontal) con la venta media por estanco (eje vertical), coloreando cada punto según la provincia. El patrón que se observa no es una relación positiva clara entre renta y venta por punto de venta; de hecho, varias de las provincias con renta más ajustada muestran ventas por estanco similares o superiores a las de provincias de renta alta, lo que apunta a que el consumo de tabaco en el canal estanco no está determinado principalmente por el nivel de renta, sino posiblemente por otros factores como la densidad de población, el turismo o los hábitos de consumo locales. Este hallazgo resulta interesante para el TFM porque contradice la hipótesis intuitiva de que a mayor renta correspondería mayor gasto por punto de venta.

13.2. Ranking de provincias por volumen

La tabla lateral ordena de forma exacta las provincias por ventas netas totales, complementando de forma numérica el gráfico de dispersión y facilitando la consulta puntual de cifras concretas, algo especialmente útil durante la defensa del trabajo ante posibles preguntas sobre una provincia específica.

13.3. Ventas por tipo de ubicación

Este gráfico de barras clasifica las ventas según la tipología de ubicación del estanco (cualquier zona genérica, pueblo, frontera, ciudad, zona rural, zona vacacional, zona de

escape/ocio y zona de ocio nocturno). La categoría genérica y la de pueblo concentran el mayor volumen, lo que sugiere que buena parte de la red comercial se apoya en un tejido de estancos de proximidad y de núcleos de población medianos, más que en ubicaciones especializadas de tipo turístico o fronterizo, que si bien son relevantes en términos de rotura de stock (como se verá en la hoja siguiente), no lo son tanto en volumen absoluto de venta.

13.4. Ventas por tamaño del local

El último gráfico de esta hoja desagrega las ventas por el tamaño en metros cuadrados del local. Los locales de tamaño reducido (entre 2 y 20 m²) concentran la mayor parte de las ventas, lo cual es coherente con la naturaleza del estanco como establecimiento tradicionalmente pequeño y especializado, y permite descartar que el tamaño del local sea un factor limitante del volumen de negocio dentro de los rangos observados.

14. STOCK Y LOGÍSTICA

Esta hoja se centra en la calidad de la cadena de suministro, analizando la rotura de stock (situaciones en las que el punto de venta se queda sin producto disponible) y su relación con el formato de tienda, la ubicación geográfica y la existencia de una ruta de reparto planificada.

14.1. Indicadores globales

Se muestran dos cifras de síntesis: una tasa de rotura de stock global del 0,08 %, que confirma un nivel de servicio logístico elevado, y una media de reposición (delivery) de 1,08 unidades de reparto por registro, que describe la intensidad media de las visitas de reposición a los puntos de venta.

14.2. Rotura de stock por formato

El gráfico compara la tasa de rotura entre los formatos ATA, ASL y ETO. El formato ATA presenta la tasa de rotura más elevada de los tres, seguido de ASL y, en último lugar, ETO. Este resultado es relevante porque, combinado con el hallazgo de la hoja anterior (ASL concentra la mayoría del volumen de venta), permite matizar que el formato con mayor rotura relativa no es necesariamente el que más vende, lo que sugiere que las causas de la rotura de stock están más relacionadas con la operativa logística propia de cada formato que con la presión de demanda.

14.3. Tasa de rotura de stock por provincia

El gráfico de barras horizontales muestra una notable heterogeneidad territorial: Segovia destaca con una tasa de rotura sensiblemente superior al resto de provincias, seguida a distancia por La Rioja, Toledo y Huelva, mientras que provincias como Zaragoza o Ávila presentan tasas mínimas. Esta dispersión indica que la rotura de stock no depende únicamente del volumen de venta de la provincia (Segovia no es de las provincias con mayor volumen), sino de factores logísticos particulares —posiblemente relacionados con la distancia a los centros de distribución o la frecuencia de las rutas de reparto— que merecen una lectura cualitativa complementaria en la memoria del TFM.

14.4. Rotura por ubicación

Al desagregar la rotura de stock por tipo de ubicación, las zonas rurales (countryside) y de escape/ocio presentan las tasas más elevadas, por delante de las zonas de frontera y vacacionales, mientras que los pueblos y núcleos genéricos muestran tasas más contenidas. Este patrón es coherente con la lógica logística: cuanto más alejado o disperso está el punto de venta de las rutas de reparto habituales, mayor es el riesgo de desabastecimiento puntual.

14.5. Efecto de la ruta de reparto

El gráfico final de esta hoja es, probablemente, el hallazgo más claro de todo el bloque logístico: el porcentaje de registros con entrega efectiva es sustancialmente más alto en los puntos de venta que cuentan con una ruta de reparto asignada frente a los que no la tienen, donde la proporción de entregas es prácticamente residual. Este resultado permite afirmar, con respaldo cuantitativo, que la planificación de rutas es el factor operativo con mayor capacidad explicativa sobre la regularidad del servicio de reposición, más incluso que el formato o la ubicación del estanco.

15. ESTACIONALIDAD

La última hoja analiza el comportamiento de la venta y la reposición a lo largo del tiempo, con dos niveles de granularidad: el día de la semana y la condición de festivo frente a laborable.

15.1. Indicadores globales

Las tres tarjetas de cabecera resumen los hallazgos temporales principales: una venta media por registro de 2,05 unidades, un 19,0 % de las ventas concentrado en fin de semana, y una diferencia del -1,3 % en la venta media en días festivos respecto a los laborables.

15.2. Venta media por día

El gráfico muestra que el viernes es el día de mayor venta media por registro, mientras que el domingo presenta el valor más bajo. El resto de días laborables (lunes a jueves) se mantienen en un rango bastante estable y similar entre sí. Este patrón de repunte los viernes es habitual en el comercio de proximidad y puede asociarse al comportamiento de compra previo al fin de semana.

15.3. Volumen por día de la semana

A diferencia de la venta media (que mide intensidad por registro), este gráfico refleja el volumen total de ventas netas por día. Aquí el domingo destaca de forma muy marcada por su volumen extremadamente bajo en comparación con el resto de la semana, lo que resulta coherente con el cierre parcial o la menor actividad de apertura de los estancos en domingo. Lunes y viernes concentran el mayor volumen agregado, reforzando la idea de picos de actividad al inicio y al final de la semana laboral.

15.4. Reposición media por día

El gráfico de reposición (delivery) muestra actividad de reparto de lunes a viernes, con valores relativamente homogéneos entre sí, y una caída total a cero los sábados y domingos. Este hallazgo confirma que la logística de reposición está planificada exclusivamente en días laborables, sin actividad de reparto en fin de semana, lo cual es coherente con el hallazgo de la hoja de Stock y Logística sobre la importancia de la ruta planificada, y permite concluir que el fin de semana no solo presenta menor venta, sino también ausencia total de reabastecimiento, un factor a tener en cuenta si se quisiera reforzar el servicio en esos días.

15.5. Efecto festivo frente a laborable

El indicador de $-1,3\%$ contradice la hipótesis intuitiva de que los días festivos, al implicar mayor tiempo libre y presencia en la calle, deberían asociarse a un repunte de las ventas de tabaco. En el periodo analizado ocurre justo lo contrario: la venta media en festivo es ligeramente inferior a la de un día laborable. Esta contra-intuición constituye uno de los hallazgos más interesantes del análisis, ya que aporta evidencia empírica frente a una asunción de partida razonable pero no confirmada por el dato, y es un ejemplo claro de por qué el análisis de datos aporta valor frente a la mera intuición de negocio.

16. SÍNTESIS DE HALLAZGOS

A modo de cierre, se recogen en la siguiente tabla los principales hallazgos obtenidos a través del informe, organizados por hoja de análisis, que constituyen la base de las conclusiones del TFM:

Hoja	Hallazgo principal
Resumen Ejecutivo	El negocio está fuertemente concentrado en el formato ASL (65,76 % del volumen) y liderado por Madrid, Barcelona y Valencia en ventas netas.
Geografía y Renta	No se observa una relación positiva clara entre renta provincial y venta media por es *tanco, lo que descarta la renta como principal factor explicativo del consumo.
Stock y Logística	La existencia de una ruta de reparto planificada es el factor con mayor capacidad explicativa sobre la regularidad de las entregas, por encima del formato o la ubicación.
Estacionalidad	Los festivos no incrementan la venta media (-1,3 %) y la reposición se concentra exclusivamente en días laborables, con nulidad total el fin de semana.

Estos cuatro hallazgos, junto con la limitación de cobertura temporal señalada en la introducción, conforman el cuerpo de resultados sobre el que se apoya la discusión y las conclusiones del Trabajo de Fin de Máster.

17. CONCLUSIONES

17.1. Principales hallazgos de negocio

La integración de los hallazgos obtenidos a lo largo del trabajo permite extraer un conjunto reducido de conclusiones de negocio con implicación directa para Altadis / Imperial Brands.

Concentración del negocio en el formato ASL: el 65,76% del volumen de ventas se concentra en estancos de formato ASL, frente al 23,48% de ETO y el 10,76% de ATA, con Madrid, Barcelona y Valencia como provincias líderes en ventas netas. El negocio no está homogéneamente repartido, lo que tiene implicaciones tanto comerciales como logísticas.

La renta provincial no explica el comportamiento de venta por estanco: el análisis de dispersión entre renta media provincial y venta media por punto de venta no muestra una relación positiva clara, lo que descarta la renta como principal factor explicativo del consumo y apunta a otras variables —densidad de población, turismo o hábitos locales— como determinantes más plausibles.

La rotura de stock es un fenómeno logístico, no de demanda: el modelo de árbol de decisión atribuye el 82% de su capacidad predictiva a la variable Delivery_Unidades, confirmando que la disponibilidad de producto en el punto de venta depende fundamentalmente de la reposición y no del calendario ni de la presión de demanda. Esta lectura es coherente con el hallazgo de que el 96% de los outlets sufre roturas en algún momento del periodo y con la sobrerrepresentación del formato ATA (3 veces superior a la media) en las incidencias.

La ruta de reparto planificada es el factor logístico más explicativo: los puntos de venta con ruta de reparto asignada presentan una proporción de entregas efectivas sustancialmente superior a los que no la tienen, por encima incluso del efecto del formato o de la ubicación del estanco.

El comportamiento de venta, no el tamaño del local, segmenta mejor la red: la clusterización en cinco perfiles de outlet muestra que el volumen de venta y la diversidad de catálogo separan los grupos con mayor claridad que variables puramente descriptivas como el tamaño físico o la renta provincial, lo que sugiere apoyar las decisiones de priorización comercial en el histórico de venta de cada outlet.

Existe un patrón semanal robusto y una estacionalidad festiva contra-intuitiva: la venta media alcanza su máximo los viernes y su mínimo los domingos, mientras que la reposición se concentra exclusivamente en días laborables, con nulidad total el fin de semana. Además, la venta media en festivo resulta ligeramente inferior (-1,3%) a la de un día laborable, contradiciendo la hipótesis intuitiva de que el mayor tiempo libre asociado a los festivos debería traducirse en un repunte de las ventas de tabaco.

17.2. Limitaciones del estudio

Como se ha señalado a lo largo de la memoria, los resultados de este trabajo deben interpretarse a la luz de una serie de limitaciones que condicionan tanto el alcance como la generalización de las conclusiones.

Truncamiento del fichero de ventas: el dataset de origen se encuentra truncado en el límite máximo de filas de Excel (1.048.575 registros), lo que reduce la cobertura real de información al periodo comprendido entre el 9 de marzo y el 6 de septiembre de 2015, sin que existan meses completos ausentes dentro de esa ventana. Todas las cifras y patrones presentados en este trabajo se refieren, por tanto, al periodo efectivamente cubierto por el dato, y no deben extrapolarse a una lectura anual completa.

Subnotificación de roturas de stock: la auditoría de calidad detectó indicios de que no todos los estancos declaran sistemáticamente las roturas, por lo que el número real de incidencias es presumiblemente superior al registrado en OoSDay.

Desequilibrio extremo de la variable objetivo en el modelo predictivo: con solo un 0,08% de casos positivos sobre el total de registros, la capacidad de los modelos de clasificación para lograr una precisión operativamente útil se ve limitada de forma estructural, independientemente de la técnica de balanceo empleada.

Cobertura incompleta de variables descriptivas: el 17,5% de los outlets (626 de 3.583) no dispone de información de tamaño del local, y esta variable se codificó mediante aproximaciones declaradas, por lo que su tratamiento en los modelos debe interpretarse como una escala ordinal aproximada.

Solapamiento entre segmentos de la clusterización: el silhouette score obtenido (0,233) es moderado, lo que indica que los cinco perfiles de outlet son interpretables pero conviven con un solapamiento natural entre ellos.

Modelo de previsión de demanda pendiente: la tercera pieza analítica prevista dentro del objetivo 4 —un modelo de series temporales en R para anticipar demanda y riesgo de desabastecimiento— no se ha completado dentro del alcance de esta memoria y se traslada como línea de trabajo futura.

17.3. Recomendaciones para Altadis / Imperial Brands

A partir de los hallazgos anteriores, se plantean las siguientes recomendaciones orientadas a la acción comercial y logística de la compañía.

Priorizar la monitorización de la reposición sobre la previsión de demanda a corto plazo: dado que la variable de entregas concentra la mayor parte de la capacidad explicativa sobre la rotura de stock, cualquier iniciativa orientada a reducir las roturas debería centrarse primero en anticipar y corregir fallos en el proceso de reparto, antes que en modelos de previsión de demanda por sí solos.

Diseñar una política de reposición diferenciada por formato: el formato ATA concentra una tasa de rotura desproporcionadamente alta en relación con su peso en volumen de venta, por lo que podría beneficiarse de una frecuencia o prioridad de reparto distinta a la del resto de la red.

Reforzar la cobertura logística en zonas rurales y de escape/ocio: estas tipologías de ubicación presentan las tasas de rotura más elevadas, de forma coherente con su mayor distancia o dispersión respecto a las rutas de reparto habituales.

Apoyar las decisiones de priorización comercial en el comportamiento histórico de venta: más que en el tamaño físico del local o en la renta provincial de la zona, ya que estas variables descriptivas no explican de forma consistente las diferencias de rendimiento entre outlets.

Resolver el truncamiento del dato en origen antes de tomar decisiones de alcance anual: se recomienda trabajar sobre los ficheros CSV originales o directamente sobre el Data Warehouse en SQL, sin la restricción de filas de Excel, de cara a análisis que requieran cobertura temporal completa.

17.4. Líneas futuras de trabajo

Este trabajo abre varias líneas de continuidad que no ha sido posible abordar dentro de su alcance actual.

Completar la cobertura temporal del análisis: reconstruyendo el histórico completo de 2015 a partir de los ficheros CSV originales o de la infraestructura SQL, superando la limitación de truncamiento que condiciona los resultados presentados en este documento.

Finalizar el modelo de previsión de demanda: desarrollando en R el modelo de series temporales previsto dentro del objetivo 4, que permitiría anticipar tanto la evolución de la demanda como el riesgo de desabastecimiento en outlets concretos.

Explorar técnicas de balanceo más avanzadas para la predicción de rotura de stock: como el sobremuestreo sintético (SMOTE), el submuestreo controlado o enfoques de aprendizaje sensible al coste, con el fin de mejorar el equilibrio entre precisión y cobertura que limita a los tres modelos evaluados en este trabajo.

Incorporar fuentes externas adicionales: en particular los datos del Comisionado para el Mercado de Tabacos y las memorias públicas de los principales competidores (BAT, JTI, PMI), para contextualizar el desempeño de Altadis dentro del conjunto del sector.

Profundizar en la clusterización de outlets: incorporando variables de comportamiento adicionales —por ejemplo, la estacionalidad propia de cada punto de venta o su exposición a roturas recurrentes— que permitan reducir el solapamiento actual entre segmentos y afinar su utilidad para la segmentación comercial.

17.5. Reflexión final

Más allá de los resultados técnicos concretos, este Trabajo de Fin de Máster ha permitido aplicar de forma integrada el conjunto de herramientas y metodologías trabajadas a lo largo del máster —Power Query, SQL, Python, R y Power BI— sobre un caso real con datos imperfectos, en colaboración con una compañía del sector tabacalero. Esa imperfección, lejos de ser un obstáculo, ha resultado formativa: gran parte del valor del trabajo reside precisamente en documentar de forma rigurosa las limitaciones del dato —el truncamiento del fichero de ventas, la subnotificación de roturas o el desequilibrio de la variable objetivo— en lugar de ocultarlas, y en mostrar que incluso con esas restricciones es posible construir un repositorio de datos fiable y un conjunto de indicadores útiles para la toma de decisiones.

En definitiva, el proyecto confirma la hipótesis de partida planteada en la introducción: integrar en una estructura de datos única la información dispersa de ventas, entregas, roturas de stock, rutas y características del punto de venta permite transformar datos operativos en conocimiento accionable, aportando una base sólida sobre la que Imperial Brands puede apoyar decisiones comerciales, logísticas y estratégicas dentro de su red de estancos en España.

BIBLIOGRAFÍA

BBDD → (INE) Relación de municipios y códigos por provincias y comunidades autónomas

https://www.ine.es/CDINEbase/consultar.do?mes=&operacion=Relaci%F3n+de+municipios+y+c%F3digos+por+provincias+y+comunidades+aut%F3nomas&id_oper=lr

Atlas de distribución de renta de los hogares. Serie 2015-2023 | Renta media neta por provincia (INE)

<https://www.ine.es/jaxiT3/Tabla.htm?t=53689>

Instituto Nacional de Estadística. (2026). Cálculo de variaciones del Índice de Precios de Consumo.

<https://www.ine.es/varipc/verVariaciones.do>

BOE (2014). Resolución de 17 de octubre de 2014, de la Dirección General de Empleo, por la que se publica la relación de fiestas laborales para el año 2015 (BOE-A-2014-10823).

Instituto Nacional de Estadística. (2024). Relación de municipios y códigos por provincias y comunidades autónomas. <https://www.ine.es/CDINEbase/consultar.do>

Instituto Nacional de Estadística. (2024). Atlas de distribución de renta de los hogares. Renta media neta por persona por provincias (serie 2015-2023).

<https://www.ine.es/jaxiT3/Tabla.htm?t=53689>

Instituto Nacional de Estadística. (2026). Calculadora de variaciones del Índice de Precios de Consumo. <https://www.ine.es/varipc/verVariaciones.do>

Boletín Oficial del Estado. (2014). Resolución de 17 de octubre de 2014, de la Dirección General de Empleo, por la que se publica la relación de fiestas laborales para el año 2015 (BOE-A-2014-10823).

<https://www.boe.es/boe/dias/2014/10/24/pdfs/BOE-A-2014-10823.pdf>

Altadis / Imperial Brands. (2024).

Sitio web corporativo. <https://www.altadis.com/>

Microsoft. (2024). Documentación de Power BI.

<https://learn.microsoft.com/es-es/power-bi/>

Microsoft. (2024). Documentación de SQL Server.

<https://learn.microsoft.com/es-es/sql/sql-server/>

Scikit-learn developers. (2024). Scikit-learn: Machine learning in Python.

<https://scikit-learn.org/stable/>

ANEXO. VALIDACIÓN FINAL DEL MODELO DIMENSIONAL (DATA WAREHOUSE)

1. Resumen de tablas físicas

Tabla	Filas	Rol en el esquema
FACT_Ventas	1.048.575	Tabla de hechos. Una fila por venta.
DIM_Producto	59	Dimensión. Catálogo completo de productos.
DIM_Outlet	3.583	Dimensión. Catálogo completo de outlets, con provincia y renta.
DIM_Fecha	182	Dimensión. Calendario diario de la ventana real de SalesDay.

Tabla A1. Tablas físicas del modelo dimensional final. Elaboración propia.

2. Verificación de integridad referencial

Se ha comprobado, en ambas direcciones, que no existen registros huérfanos entre la tabla de hechos y sus tres dimensiones. Los tres controles de integridad arrojaron resultado 0:

Comprobación	Consulta ejecutada	Resultado
Ventas sin outlet en DIM_Outlet	<pre>FACT_Ventas WHERE Affiliated_Code NOT IN (SELECT Affiliated_Code FROM DIM_Outlet)</pre>	0 registros

Ventas sin producto en DIM_Producto	FACT_Ventas WHERE Product_Code NOT IN (SELECT Product_Code FROM DIM_Producto)	0 registros
Ventas sin fecha en DIM_Fecha	FACT_Ventas WHERE Sales_DAY NOT IN (SELECT Fecha_AAAAMMDD FROM DIM_Fecha)	0 registros

El resultado de las tres comprobaciones confirma que el 100% de los registros de FACT_Ventas referencia entidades existentes en sus tres dimensiones, sin huérfanos en ninguna dirección.

3. Comandos representativos del proceso de construcción

Resolución del duplicado de Product (Natu122) mediante CTE y ROW_NUMBER():

```
WITH Product_Clean AS (
    SELECT Product_Code, SIZE, Format,
    ROW_NUMBER() OVER (
    PARTITION BY Product_Code
    ORDER BY CASE WHEN Format = 'ATA' THEN 1 ELSE 2 END
    ) AS rn
    FROM Product
)
SELECT Product_Code, SIZE, Format
FROM Product_Clean
WHERE rn = 1;
```

Cálculo de entregas agregadas mediante JOIN (sustituyendo la subconsulta correlacionada inicial):

```
UPDATE t
SET t.Delivery_Unidades = ISNULL(d.total, 0)
FROM TablaMaestra5 t
LEFT JOIN (
    SELECT Delivery_DAY, Affiliated_Code, Product_Code,
    SUM(Delivery_Uds) AS total
    FROM DeliveryDay
    GROUP BY Delivery_DAY, Affiliated_Code, Product_Code
```

```
) d ON d.Delivery_DAY      = t.Sales_DAY
      AND d.Affiliated_Code = t.Affiliated_Code
      AND d.Product_Code   = t.Product_Code;
```

Materialización final del esquema en estrella:

```
SELECT DISTINCT Product_Code, SIZE, Format
INTO DIM_Producto FROM TablaMaestra5;

SELECT a.*, r.Valor AS Renta_Media_Provincial
INTO DIM_Outlet
FROM AffiliatedOutlets_Enriched a
LEFT JOIN RentaProvincialNE_2015 r ON a.PROVINCIA = r.Nombre;

SELECT Sales_DAY, Affiliated_Code, Product_Code, Sales_Uds,
      Delivery_Unidades, Flag_OoS, Flag_Ruta, Es_Festivo
INTO FACT_Ventas FROM TablaMaestra5;
```

ANEXO B. CUADRO DE MANDO POWER BI: ESTRUCTURA Y VISUALIZACIONES

El cuadro de mando desarrollado en Power BI (fichero TFM_PBI.pbix) se organiza en cuatro páginas, cada una correspondiente a uno de los bloques de análisis documentados en los capítulos 12 a 15 de esta memoria. La siguiente tabla resume las visualizaciones incluidas en cada página.

Página	Visualizaciones incluidas
Resumen Ejecutivo	3 tarjetas de indicadores (unidades netas vendidas, estancos con actividad, productos con ventas), gráfico de barras agrupado, segmentador, gráfico de anillo (mix de ventas por formato)
Geografía y Renta	Gráfico de dispersión (ventas por estanco frente a renta), tabla de ranking de provincias por volumen, 2 gráficos de columnas agrupadas (ventas por tipo de ubicación y por tamaño del local)

Stock y Logística	2 tarjetas de indicadores, gráfico de barras, gráfico de columnas (rotura de stock por formato), gráfico de columnas agrupadas (efecto de la ruta de reparto), gráfico de barras agrupadas (rotura por ubicación)
Estacionalidad	3 tarjetas de indicadores, 3 gráficos de columnas agrupadas (venta media por día, volumen por día de la semana, reposición media por día)

Tabla A2. Estructura de páginas y visualizaciones del cuadro de mando Power BI. Elaboración propia.

Las cuatro páginas comparten un mismo tema visual personalizado y permiten filtrado cruzado entre visualizaciones dentro de cada página, de forma que la selección de una provincia, formato o rango de fechas actualiza el resto de gráficos y tarjetas de la misma vista.

ANEXO C. NOTEBOOK DE PREDICCIÓN DE ROTURA DE STOCK

(OBJETIVO 4)

C.1. Planteamiento y variables

El notebook `Prediccion_RoturaStock_Altadis.ipynb` entrena y compara tres modelos de clasificación binaria para predecir si un registro de venta (combinación día-outlet-producto) presentará rotura de stock declarada ($\text{Flag_OoS} = 1$) o no ($\text{Flag_OoS} = 0$), a partir del fichero `TablaModPredictivoOutOfStock.csv`.

Variable objetivo: `Flag_OoS`, con un desequilibrio extremo de solo 757 casos positivos sobre 950.217 registros (0,08 %).

Variables predictoras: `Es_Festivo`, `Flag_Ruta`, `Delivery_Unidades`, `Dia_Semana`, `Es_Fin_Semana`, `Tam_m2`, `Renta_Media_Provincial` y `Format`.

La variable `Sales_Uds` se excluye deliberadamente como predictor, ya que la rotura de stock es causa de una venta baja o nula y no al revés; incluirla introduciría fuga de información (data leakage). La codificación de `Tam_m2` como variable ordinal numérica sigue el mismo criterio documentado en el análisis de clustering (Anexo D), y las variables categóricas restantes se codifican mediante one-hot encoding.

C.2. Modelos comparados

Dado el desequilibrio extremo de la variable objetivo, los tres modelos se entrenan con técnicas de balanceo (`class_weight='balanced'` en regresión logística y árbol de decisión; `scale_pos_weight` en XGBoost), y se evalúan sobre una partición train/test estratificada (80/20) que preserve la proporción de roturas en ambos conjuntos.

Regresión logística balanceada: modelo base e interpretable, utilizado como referencia de comparación.

```
modelo_log = LogisticRegression(max_iter=1000, class_weight='balanced',  
random_state=42)
```

Árbol de decisión: se entrena primero un árbol sin podar para diagnosticar sobreajuste comparando accuracy en train y test, y a continuación un árbol podado (profundidad máxima 4, mínimo 20 observaciones por hoja) y balanceado, que permite además extraer la importancia relativa de cada variable predictora.

```
arbol = DecisionTreeClassifier(max_depth=4, min_samples_leaf=20,  
class_weight='balanced', random_state=42)
```

XGBoost balanceado: boosting de árboles, habitualmente el modelo con mejor rendimiento predictivo. El parámetro `scale_pos_weight` —equivalente en XGBoost a `class_weight='balanced'`— se calcula como la proporción entre la clase negativa y la positiva.

```
peso_positivo = (y_train == 0).sum() / (y_train == 1).sum()  
xgb_modelo = XGBClassifier(max_depth=4, learning_rate=0.1, n_estimators=200,  
scale_pos_weight=peso_positivo, random_state=42)
```

C.3. Criterio de evaluación

Dado que un modelo que predijese siempre “sin rotura” acertaría ya en el 99,92 % de los casos, el Accuracy no es una métrica informativa en este problema. El notebook prioriza en su lugar el Recall de la clase “con rotura” —de todas las roturas reales, qué proporción es capaz de anticipar el modelo— junto con la Precision y el F1-score, comparando los tres modelos mediante un cuadro de métricas y un gráfico de barras conjunto.

ANEXO D. NOTEBOOK DE CLUSTERING DE OUTLETS (OBJETIVO 4)

D.1. Variables y estandarización

El notebook Clustering_Outlets_Altadis.ipynb segmenta los 2.957 outlets con tamaño conocido (excluyendo los que tienen Tam_m2 = 'N.D.') combinando variables descriptivas —tamaño del local y renta media provincial— con variables de comportamiento de venta: volumen total, tasa de rotura de stock y diversidad de catálogo (número de productos distintos vendidos).

Se excluyen del algoritmo la provincia (alta cardinalidad y parcialmente redundante con la renta) y el tipo de ubicación, que se reserva como variable de caracterización cualitativa posterior. Las cinco variables de entrada se estandarizan (media 0, desviación 1) antes de aplicar k-means, dado que están en escalas muy distintas entre sí.

D.2. Elección del número de clusters

Se evalúan valores de k entre 2 y 8 mediante el método del codo (inercia) y el coeficiente de silueta (silhouette score). Aunque el silhouette score máximo se alcanza en k=7 (0,254), se opta por k=5 (0,233): la diferencia es reducida y un número menor de clusters resulta más manejable para la interpretación de negocio y la presentación de resultados, sin pérdida sustancial de calidad del agrupamiento.

D.3. Detección y exclusión de un cluster degenerado

Una primera ejecución de k-means con k=5 sobre el conjunto completo produjo un cluster de únicamente 5 observaciones. La inspección de estos outlets reveló una tasa de rotura de stock entre 50 y 90 veces superior a la media de la red (0,05–0,086 frente a 0,0009 de media general). Por su reducido tamaño muestral no constituyen un segmento de negocio, sino un hallazgo cualitativo independiente —outlets con un problema de suministro extremo y aislado que merece atención prioritaria—, documentado aparte del análisis principal. Se excluyen del clustering y el proceso se repite sobre los 2.952 outlets restantes, confirmándose que k=5 sigue siendo una elección razonable.

D.4. Perfiles finales de los cinco clusters

Cluster	N.º outlets	Perfil
0	715	Tamaño pequeño, renta provincial alta, venta media.
1	959	El más numeroso. Tamaño pequeño, renta baja, venta baja y catálogo reducido: el segmento de menor rendimiento comercial.
2	727	Venta notablemente superior al resto (casi el triple de la media) y mayor diversidad de catálogo: el segmento de mejor desempeño.
3	193	Perfil similar al promedio, pero con una tasa de rotura de stock más elevada que el resto de grupos, sin llegar a ser un caso extremo.
4	358	Único grupo diferenciado claramente por el tamaño físico del local (28 m ² de media frente a 7-9 m ² del resto), sin que ello se traduzca en un volumen de venta proporcionalmente superior.

Tabla A3. Perfiles de los cinco segmentos de outlet resultantes del clustering. Elaboración propia.

El comportamiento de venta —volumen y diversidad de catálogo— separa los grupos con más claridad que las variables puramente descriptivas (tamaño del local, renta provincial), lo que confirma que el tamaño físico del local no es el factor que mejor explica las diferencias de rendimiento comercial entre outlets.